

通过对非线性动力系统进行稀疏识别从数据中发现控制方程

Steven L. Brunton^{a,1}, Joshua L. Proctor^b, 和 J. Nathan Kutz^c

华盛顿大学西雅图分校机械工程系, 邮编98195; ^b疾病建模研究所, 贝尔维尤, 邮编98005; 以及^c华盛顿大学西雅图分校应用数学系, 邮编98195

由普林斯顿大学威廉·比亚莱克编辑, 普林斯顿, 新泽西州, 并于2016年3月1日批准 (2015年8月31日收到审阅)

从数据中提取控制方程是许多不同科学和工程领域中的一个核心挑战。数据丰富, 而模型通常难以获得, 例如在气候科学、神经科学、生态学、金融和流行病学中, 仅举几个例子。在这项工作中, 我们将稀疏性促进技术和机器学习与非线性动力系统相结合, 从噪声测量数据中发现控制方程。关于模型结构的唯一假设是只有少数重要项控制动力学, 因此在可能的函数空间中方程是稀疏的; 在适当的基下, 这一假设适用于许多物理系统。特别地, 我们使用稀疏回归来确定动态控制方程中所需的最少项, 以准确表示数据。这产生了简约模型, 在准确性与模型复杂性之间取得平衡, 以避免过拟合。我们在广泛的场景中演示了该算法

从数据中研究动力系统。然而, 符号回归成本高, 不适合扩展到大型感兴趣系统, 并且除非特别注意明确平衡模型复杂性与预测能力, 否则可能容易过拟合。在参考文献4中, 使用帕累托前沿来寻找简约模型。还有其他技术处理动力系统发现问题的各个方面。这些包括从时间序列数据中发现控制方程的方法(6)、无方程建模(7)、经验动力学建模(8, 9)、建模涌现行为(10)以及动态的自动推断(11–13); 参考文献12提供了出色的综述。

非线性动力学的稀疏识别 (SINDy)

在这项工作中, 我们从稀疏回归 (14–16) 和压缩感知 (17–22) 的角度重新审视动力系统发现问题。特别地, 我们利用这样一个事实: 大多数物理系统只有少数相关项能够定义其动态, 使得控制方程在高维非线性函数空间中是稀疏的。在动力系统中结合稀疏方法是相当新的 (23–30)。在这里, 我们考虑形式为的动力系统 (31)

$$\frac{d}{dt}\mathbf{x}(t) = \mathbf{f}(\mathbf{x}(t)). \quad [1]$$

向量 $\mathbf{x}(t) \in \mathbb{R}^n$ 表示系统在时间 t 的状态, 函数 $\mathbf{f}(\mathbf{x})$ 表示定义系统运动方程的动态约束, 例如牛顿第二定律。随后, 动力学将被推广以包括参数化、时间依赖性和外力作用。

动力系统 | 机器学习 | 稀疏回归 | 系统识别 | 优化

机器学习(1)和数据科学(2)的进步承诺将带来复杂数据分析和理解的复兴, 从海量多模态数据中提取人类难以掌握的模式。然而, 尽管基于统计关系理解静态数据的工具发展迅速, 从大数据中提炼动态过程的物理模型的进展却很缓慢。这限制了数据科学模型在所采样和构建的吸引子之外推断动态行为的能力。

可以将这一点与开普勒和牛顿的发现进行类比。开普勒凭借当时最全面、最精确的行星数据, 建立了一个以数据为驱动的行星运动模型, 从而得出了著名的椭圆轨道。然而, 这是一种基于吸引子的世界观, 它并未解释产生行星轨道的基本动态关系, 也没有提供一个模型来说明这些天体在受到扰动时会如何反应。相比之下, 牛顿发现了动量和能量之间的动态关系, 这种关系描述了导致这些椭圆轨道的基本过程。这个动态模型可以推广, 用于预测在没有数据采集的情况下的行为。牛顿的模型在工程设计上被证明异常稳健, 使得登陆月球成为可能, 而仅依靠开普勒的模型是不可能实现的。

Bongard 和 Lipson (3) 以及 Schmidt 和 Lipson (4) 的一项开创性突破导致了一种从数据中确定非线性动力系统潜在结构的新方法。该方法使用符号回归 [即遗传编程 (5)] 来寻找非线性微分方程, 并在模型的复杂度 (以项的数量衡量) 与模型精度之间取得平衡。由此得到的模型识别实现了物理学和工程界长期追求的一个目标, 即发现

重要性

理解自然界中的动态约束和平衡促进了知识的快速发展, 并推动了技术进步, 包括飞机、内燃机、卫星和电力。本研究开发了一种新颖的框架, 通过数据测量从简单地发现动力系统的基本控制方程, 利用稀疏技术和机器学习的进展。所得到的模型是简约的, 在模型复杂性与描述能力之间取得平衡, 同时避免过拟合。有许多关键的数据驱动问题, 例如从神经记录中理解认知、推断气候模式、确定金融市场的稳定性、预测和抑制疾病传播, 以及控制湍流以实现更环保的交通和能源。在数据丰富且规律难以捉摸的情况下, 基于数据的动力学发现将在这些努力中继续发挥重要作用。

Author contributions: S.L.B., J.L.P., and J.N.K. designed research; S.L.B. performed research; S.L.B., J.L.P., and J.N.K. analyzed data; and S.L.B. wrote the paper.

The authors declare no conflict of interest.

This article is a PNAS Direct Submission.

Freely available online through the PNAS open access option.

¹To whom correspondence should be addressed. Email: sbrunton@uw.edu.

This article contains supporting information online at www.pnas.org/lookup/suppl/doi:10.1073/pnas.1517384113/-DCSupplemental.

关键的观察是，对于许多感兴趣的系统，函数 f 仅由少数几项组成，使其在可能的函数空间中显得稀疏。近期在压缩感知和稀疏回归方面的进展使这种稀疏性观点变得有利，因为现在可以在不进行组合上不可行的蛮力搜索的情况下确定右侧项哪些是非零的。这保证了使用符合摩尔定律的大规模问题适应性的凸方法能够以高概率找到稀疏解。由此得到的稀疏模型识别天然地平衡了模型复杂性（即右侧动态的稀疏性）与精度，避免了模型对数据的过拟合。Wang 等人 (23) 已经使用压缩感知来识别非线性动力学并预测灾难；在这里，我们提倡使用稀疏回归来减轻噪声。

为了从数据中确定函数 f ，我们收集状态 $x(t)$ 的时间历史，并测量其导数 $\dot{x}(t)$ 或者从 $x(t)$ 数值近似其导数。数据在若干时间 $t_1, t_2, t_3, \dots, t_m$ 处采样，并整理成两个矩阵：

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}^T(t_1) \\ \mathbf{x}^T(t_2) \\ \vdots \\ \mathbf{x}^T(t_m) \end{bmatrix} = \begin{bmatrix} x_1(t_1) & x_2(t_1) & \cdots & x_n(t_1) \\ x_1(t_2) & x_2(t_2) & \cdots & x_n(t_2) \\ \vdots & \vdots & \ddots & \vdots \\ x_1(t_m) & x_2(t_m) & \cdots & x_n(t_m) \end{bmatrix} \downarrow \text{time}$$

$$\dot{\mathbf{X}} = \begin{bmatrix} \dot{\mathbf{x}}^T(t_1) \\ \dot{\mathbf{x}}^T(t_2) \\ \vdots \\ \dot{\mathbf{x}}^T(t_m) \end{bmatrix} = \begin{bmatrix} \dot{x}_1(t_1) & \dot{x}_2(t_1) & \cdots & \dot{x}_n(t_1) \\ \dot{x}_1(t_2) & \dot{x}_2(t_2) & \cdots & \dot{x}_n(t_2) \\ \vdots & \vdots & \ddots & \vdots \\ \dot{x}_1(t_m) & \dot{x}_2(t_m) & \cdots & \dot{x}_n(t_m) \end{bmatrix}$$

接下来，我们构建一个由 $\mathbf{X}$ 的列的候选非线性函数组成的库 $\Theta \delta \mathbf{X} \mathbf{D}$ 。例如， $\Theta \delta \mathbf{X} \mathbf{D}$ 可能包含常数、多项式和三角函数项：

$$\Theta(\mathbf{X}) = \begin{bmatrix} 1 & \mathbf{X} & \mathbf{X}^2 & \mathbf{X}^3 & \cdots & \sin(\mathbf{X}) & \cos(\mathbf{X}) & \cdots \end{bmatrix}. \quad [2]$$

这里，更高次的多项式表示为 $\mathbf{X}^2, \mathbf{X}^3$ 等，其中 $\mathbf{X}^2$ 表示状态 x 中的二次非线性项：

$$\mathbf{X}^2 = \begin{bmatrix} x_1^2(t_1) & x_1(t_1)x_2(t_1) & \cdots & x_2^2(t_1) & \cdots & x_n^2(t_1) \\ x_1^2(t_2) & x_1(t_2)x_2(t_2) & \cdots & x_2^2(t_2) & \cdots & x_n^2(t_2) \\ \vdots & \vdots & \ddots & \vdots & \ddots & \vdots \\ x_1^2(t_m) & x_1(t_m)x_2(t_m) & \cdots & x_2^2(t_m) & \cdots & x_n^2(t_m) \end{bmatrix}.$$

$\Theta \delta \mathbf{X} \mathbf{D}$ 的每一列代表方程 1 右侧的一个候选函数。在选择这个非线性矩阵中的条目时有很大的自由度。因为我们认为在 f 的每一行中只有少数这些非线性是活跃的，所以我们可以建立一个稀疏回归问题来确定系数的稀疏向量 $\Xi = \frac{1}{2} [\xi_1 \xi_2 \cdots \xi_n]$ ，以确定哪些非线性是活跃的：

$$\dot{\mathbf{X}} = \Theta(\mathbf{X})\Xi. \quad [3]$$

如图 1 所示。每一列 ξ_k 的 Ξ 是一个稀疏系数向量，用于确定哪些项在方程 1 中某一行方程 $\dot{x}_k = f_k \delta x \mathbf{D}$ 的右侧是活跃的。一旦 Ξ 被确定，就可以如下构建每一行控制方程的模型：

$$\dot{x}_k = f_k(\mathbf{x}) = \Theta(\mathbf{x}^T)\xi_k. \quad [4]$$

请注意， $\Theta \delta x^T \mathbf{D}$ 是 x 元素的符号函数向量，相对于 $\Theta \delta \mathbf{X} \mathbf{D}$ ，后者是数据矩阵。因此，

$$\dot{\mathbf{x}} = \mathbf{f}(\mathbf{x}) = \Xi^T (\Theta(\mathbf{x}^T))^T. \quad [5]$$

方程 3 的每一列都需要进行不同的优化，以找到第 k 行方程的稀疏系数向量 ξ_k 。我们也可以对 $\Theta \delta \mathbf{X} \mathbf{D}$ 的列进行归一化，尤其是在 $\mathbf{X}$ 的条目较小时，如 SI 附录中所讨论的。

在本文的示例中，矩阵 $\Theta \delta \mathbf{X} \mathbf{D}$ 的大小为 $m \times p$ ，其中 p 是候选函数的数量， $m \gg p$ 是因为数据样本数量多于函数数量；这在受限基（例如公式 2 中的多项式基）中是可能的。在实践中，测试多种不同的函数基并使用所得模型的稀疏性和准确性作为诊断工具来确定表示动态的正确基可能会有帮助。在 SI 附录的附录 B 中，探讨了两个示例，其中稀疏识别算法失败，因为所选基中的动态不稀疏。

实际上，通常只有 $\mathbf{X}$ 可用，并且 $\dot{\mathbf{X}}$ 必须像下面所有连续时间的示例中那样通过数值近似。因此， $\mathbf{X}$ 和 $\dot{\mathbf{X}}$ 都被噪声污染，所以方程 3 并不完全成立。相反，

$$\dot{\mathbf{X}} = \Theta(\mathbf{X})\Xi + \eta \mathbf{Z}, \quad [6]$$


其中 $\mathbf{Z}$ 被建模为一个由零均值独立同分布高斯条目组成的矩阵，噪声幅度为 η 。因此，我们寻求对带噪的超定系统的稀疏解。最小绝对收缩和选择算子 (LASSO) (14, 15) 是一种 ℓ_1 正则化回归，它促进稀疏性，并且在这类数据上表现良好。然而，对于非常大的数据集，它可能计算成本高。基于顺序阈值最小二乘法的替代方法在 SI 附录的代码 1 中给出。

根据噪声情况，可能需要在求解 Ξ 之前对 $\mathbf{X}$ 和 $\dot{\mathbf{X}}$ 进行滤波。在下面的许多例子中，只有数据 $\mathbf{X}$ 可用，而 $\dot{\mathbf{X}}$ 是通过微分获得的。为了抵消微分误差，我们使用总变差正则化 (32) 对导数 (33) 进行去噪。当仅有状态数据 $\mathbf{X}$ 可用时，这种方法效果相当好，如 Lorenz 系统所示 (SI 附录，图 S7)。或者， $\mathbf{X}$ 和 $\dot{\mathbf{X}}$ 数据也可以进行滤波，例如使用参考文献 34 中描述的奇异值最优硬阈值。对噪声不敏感是从数据识别动力学算法的一个关键特性 (11–13)。

通常，感兴趣的物理系统可以自然地用少数空间变量的偏微分方程 (PDE) 表示。如果数据是从数值离散化或空间网格上的实验测量中收集的，那么状态维度 n 可能会大得难以承受。例如，在流体动力学中，即使是简单的二维和三维流动，也可能需要数万到数十亿个变量来表示离散化系统。所提出的方法不适合大的状态维度 n ，因为 Θ 随 n 的阶乘增长，并且 Eq. 4 中的 n 行方程的每一行都需要单独优化。幸运的是，许多高维感兴趣系统的发展在低维流形或吸引子上，这些可以用低秩基 Ψ (35, 36) 进行良好近似。例如，如果像 Eq. 2 中那样为高维系统收集数据 $\mathbf{X}$ ，则可以使用降维技术获得低秩近似。

所提出的非线性动力学稀疏识别 (SINDy) 方法依赖于测量变量的选择、数据质量以及稀疏化函数基。没有一种方法可以解决非线性系统识别中的所有问题，但该方法强调了这些基础选择的重要性，并可以帮助指导分析。选择测量变量和稀疏化函数基的挑战在《补充信息》附录第 4.5 节以及附录 A 和 B 中进行了探讨。

简而言之，我们需要合适的坐标和函数基以产生稀疏动力学；这些要求的可行性和灵活性在讨论和 SI 附录第 4.5 节中进行了讨论。



Brunton et al.

状态 $\mathbf{x}$ 关于时间的导数。这里，右侧的动力学在多项式空间 $\Theta\delta\mathbf{X}\mathbf{D}$ 中被识别，变量为 $\delta\mathbf{x}, \mathbf{y}, \mathbf{z}\mathbf{D}$ ，最高到五阶，尽管也可以包括其他函数，如 $\sin, \cos, \exp$ 或更高阶多项式：

$$\Theta(\mathbf{X}) = \begin{bmatrix} \mathbf{x}(t) & \mathbf{y}(t) & \mathbf{z}(t) & \mathbf{x}(t)^2 & \mathbf{x}(t)\mathbf{y}(t) & \cdots & \mathbf{z}(t)^5 \end{bmatrix}.$$

$\Theta\delta\mathbf{X}\mathbf{D}$ 的每一列表示方程 1 右侧的一个候选函数。由于在 $\mathbf{f}$ 的每一行中仅有少数这些项是活跃的，我们通过解方程 3 中的稀疏回归问题来确定系数的稀疏向量 $\Xi = \frac{1}{2} \xi_1 \xi_2 \cdots \xi_n$ ，从而确定哪些项在动力学中是活跃的。图 1 中以示意方式展示了这一过程，其中稀疏向量 ξ_k 被找到，用以将导数 $\dot{\mathbf{x}}_k$ 表示为 $\Theta\delta\mathbf{X}\mathbf{D}$ 中最少项的线性组合。

在洛伦兹示例中，捕捉吸引子上的动力学能力比预测单条轨迹的能力更为重要，因为混沌会迅速导致初始条件或模型系数的任何微小变化呈指数级发散。如图 1 所示，稀疏模型能够从混沌轨迹测量中准确再现吸引子动力学。该算法不仅识别出动力学中的正确项，而且准确地将系数确定在距真实值 0.03% 的范围内。我们还探讨了在仅有带噪状态测量时的动力学识别（SI 附录，图 S7）。正确的动力学得以识别，并且即使在相当大的噪声值下，吸引子也能保持。在 SI 附录第 4.5 节中，我们使用单个测量 $\mathbf{x}(t)$ 的时延坐标重构了洛伦兹系统中的吸引子动力学。

障碍物后涡脱落的偏微分方程。洛伦兹系统是一个低维模型，用于更逼真的高维偏微分方程模型，以模拟大气中的流体对流。许多感兴趣的系统受偏微分方程 (24) 控制，例如天气与气候、流行病学以及电力网，仅举几例。每个这些例子都具有大数据特征，由大量空间解析测量组成，包括数百万或数十亿状态，并在空间和时间上跨度数个数量级。然而，许多高维的真实世界系统在低维吸引子上演化，使得有效维度大大减小 (35)。

在这里，我们将 SINDy 方法推广到流体动力学中的一个例子，这个例子体现了上文概述的许多挑战。在来自偏微分方程的数据的背景下，我们的算法与动态模态分解有一些联系，后者是一种线性动态回归方法。

(41–43)。数据通过直接对二维纳维-斯托克斯方程 (44, 45) 进行数值模拟收集，用于雷诺数为 100 时流体绕圆柱的流动。通过这些流场测量数据识别出主导相干结构之间的非线性动态关系，而无需了解控制方程。

绕圆柱的流动是一个特别有趣的例子，因为它在流体力学和动力系统中有着丰富的历史。长期以来，人们一直理论认为湍流是随着流速增加而发生的一系列 Hopf 分岔的结果 (46)，从而在流体中产生更丰富和复杂的结构。经过 15 年，流体系统中第一次 Hopf 分岔被发现，在雷诺数为 47 时从稳定层流尾流向层流周期性涡旋脱落的过渡 (47, 48)。这一发现引发了长期的争论，即具有三次非线性的 Hopf 分岔如何在具有二次非线性的 Navier–Stokes 流体中表现出来。再经过 15 年，这个问题通过时间尺度分离和均值场模型得到了解决 (49)，如公式 8 所示。研究表明，振荡模态与基流之间的耦合产生了一个慢流形 (图 2, 左)，由此产生的代数项近似为三次非线性。

这个例子为所提出的算法提供了一个有力的测试案例，因为动力学的潜在形式花了社区中的专家近三十年的时间才被揭示。由于状态维度很大，包括数十万个网格点上的流体状态，因此首先需要降低系统的维度。POD (35, 37) 提供了一个低秩基，从而产生一系列正交模式层次，当截断时，可以在给定秩截断下捕获原系统的大部分能量。前两个能量最高的 POD 模式捕获了能量的显著部分，而稳态涡旋脱落在这些坐标下是一个极限环。为了捕获连接不稳定稳态 (图 2 中的 “C”) 与极限环均值 (49) (图 2 中的 “B”) 的瞬态动力学，增加了一个额外的模式，称为位移模式。这些模式定义了图 2 中的 $\mathbf{x}, \mathbf{y}, \mathbf{z}$ 坐标。

在上述坐标系中，圆柱动力学的平均场模型由 (49) 给出

$$\dot{\mathbf{x}} = \mu\mathbf{x} - \omega\mathbf{y} + A\mathbf{x}\mathbf{z}, \quad [8a]$$

$$\dot{\mathbf{y}} = \omega\mathbf{x} + \mu\mathbf{y} + A\mathbf{y}\mathbf{z}, \quad [8b]$$

$$\dot{\mathbf{z}} = -\lambda(\mathbf{z} - \mathbf{x}^2 - \mathbf{y}^2). \quad [8c]$$

如果 λ 很大，使得 $\mathbf{z}$ 动力学很快，那么平均流会迅速调整到由以下给出的 (慢) 流形 $\mathbf{z} = \mathbf{x}^2 + \mathbf{y}^2$ 上




图 2. 来自流体动力学的高维动力系统示例。圆柱体后方的涡脱落是一个用于流动控制的典型例子，与许多应用相关，包括车辆后的阻力减小。涡脱落是 Hopf 分岔的结果。然而，由于 Navier–Stokes 方程具有二次非线性，需要使用具有时间尺度分离的平均场模型，其中快速平均场变形从属于缓慢的涡脱落动力学。图中显示了抛物线型慢流形 (左)，以及不稳定的平衡点 (C)、平均流 (B) 和涡脱落 (A)。使用 POD 基和位移模态来降低问题的维数 (中右)。识别出的动力学在 POD 坐标中与真实轨迹高度匹配，最重要的是，它们捕捉了与平均场模型相关的二次非线性和时间尺度。

