

基于Koopman的在线识别及Sim2Real迁移用于受乌龟启发的机器人水动力建模

刘昂, 张显锐, 肖凤祺, *Graduate Student Member, IEEE*, 崔光明, 毛百金, *Graduate Student Member, IEEE*, 杨云捷, *Senior Member, IEEE*, 曲俊田, *Member, IEEE*

Abstract——本文针对仿生水下机器人动态建模中的关键挑战, 包括对先验知识的高度依赖以及难以跟踪时变模型的问题。为解决这些问题, 我们提出了一种基于Koopman算子的面向控制的在线识别框架, 并成功将其应用于海龟仿生机器人水动力学建模。首先, 通过基于Koopman理论的仿真数据离线获得先验模型。随后, 开发了一种与卡尔曼滤波集成的在线更新算法, 利用少量实验数据实时校准模型参数。仿真和实验结果表明, 所提出的Koopman模型在长期预测精度和泛化能力上均优于基线方法。在线更新后, 该模型在预测精度上比基线提高了42.13%。在方向跟踪实验中,

Index Terms——在线系统识别、生物仿真龟机器人、库普曼算子、卡尔曼滤波器。

收到日期: 2026年1月4日; 接受日期: 2026年3月30日。发表日期: 2026年4月9日; 当前版本日期: 2026年4月16日。本文在评审意见的基础上由副编辑陈Y和编辑刘X推荐发表。本工作部分由广东省科学技术厅项目2025A0505020021资助, 部分由海洋十年国际合作中心(ODCC)资助, 资助编号GHZZ3702840002024020000026, 部分由福建省海洋创新中心资助, 资助编号25FV0CZJ10和25FV0CZJ11, 部分由深海载人潜水器国家重点实验室开放基金资助, 资助编号2025SKLDMV07, 部分由深圳市科学技术计划资助, 资助编号JCYJ20240813112107010, 部分由清华大学SIGS海外科研合作基金资助, 资助编号HW2023001, 以及部分由深圳市海洋生态先进技术重点实验室资助, 资助编号ZDSYS20230626091459009。(Corresponding author: Juntian Qu.)

刘昂、张仙瑞、崔光明、毛百金和曲军天隶属于清华大学深圳国际研究生院, 中国深圳 518055 (电子邮箱: juntian.qu@sz.tsinghua.edu.cn)。肖丰琪隶属于清华大学深圳国际研究生院, 中国深圳 518055, 同时也隶属于福建海洋创新中心, 中国厦门 361102。杨云杰隶属于爱丁堡大学工程学院成像、数据与通信研究所(SMART Group), 英国爱丁堡 EH9 3BF。本文附有作者提供的可下载补充材料, 可在 <https://doi.org/10.1109/LRA.2026.3682620> 获取。数字对象唯一标识符 10.1109/LRA.2026.3682620

一、引言

仿生水下机器人(BURs)利用其卓越的生物相容性[1]和低环境干扰特性[2], 已成为海洋环境监测[3]和考古勘探[4]等领域不可或缺的工具。与传统的螺旋桨驱动自主水下航行器(AUVs)和遥控水下航行器(ROVs)相比, BURs在运动过程中产生的噪声[5]、水动力尾迹[6]和沉积物再悬浮[7]显著更低。例如, Katzschnmann等人成功利用声学通信控制机器人鱼以近距离观察海洋生物, 为在自然栖息地研究生物提供了有效平台[8]。

然而, 这些机器人的独特形态[9]、众多控制自由度[10]以及多样的仿生推进机制[11]对精确的动态建模提出了重大挑战。为了解决这一问题, 研究人员提出了各种方法[12]。王等人建立了一种用于机器人鱼的三维运动模型, 包括基于欧拉运动方程和灰箱模型水动力估计的螺旋运动[13]。尽管如此, 这些方法通常依赖于物理先验知识, 包括特定的机器人配置, 并且确定模型参数通常需要大量时间进行细致的设计和实验校准。在以前的工作[14]中, 尽管采用了单刚体动力学方程来描述两栖乌龟机器人的运动特性, 但该模型仍然难以充分捕捉由鳍肢三维振动产生的动态特征。

幸运的是, 数据驱动的方法, 例如深度学习[15]、非线性动力学稀疏识别(SINDy)[16]和库普曼算子[17], 为仅通过运动数据识别非线性系统行为提供了有前景的解决方案。深度学习涉及求解非线性优化问题, 可能存在收敛性问题[15], 而SINDy需要预先构建候选函数字典[16], 这对于先验知识有限的BURs来说可能存在限制。相比之下, 库普曼算子框架通过将非线性系统提升到无限维线性空间, 同时保留控制信息, 从而实现非线性系统的全局线性化。基于库普曼的系统识别已成功应用于各种系统, 包括球形机器人[18]、软体连续操纵器[19]和轮式机器人[20]。值得注意的是, Pan等人提出了一个用于自动化的贝叶斯库普曼框架

控制器生成,有效减少了构建提升函数的人工负担,在机器人鱼平台上已得到验证 [21]。

尽管减少了对物理先验知识的依赖,基于 Koopman 的方法仍然需要大量数据进行训练 [22]。由于实验条件的限制,获取足够稳定的 BUR 运动数据通常具有挑战性。一种可行的策略是使用动态模拟器生成多样化的运动数据以进行先验模型识别,然后用少量真实实验数据进行更新和校正,从而实现从仿真到现实 (Sim2Real) 的迁移。这一策略已在具身 AI 中被广泛采用,包括腿式和人形机器人 [23]。例如,Choi 等人提出的细粒度中等模型使强化学习代理能够很好地适应不熟悉的环境,克服了训练数据分布的限制 [24]。

此外,BUR在实际应用中面临时间变化动力学的挑战:诸如变化的有效载荷 [18]、组件的机械磨损 [13] 以及多个控制器之间的耦合 [12] 等因素都可能导致动力学参数的漂移。因此,开发能够在线跟踪模型变化的鲁棒识别算法至关重要。例如,为了应对软环境动力学模型的在线识别,Schindeler 等提出了一种两阶段多项式线性化 Hunt-Crossley 模型识别方法,通过查找表递归最小二乘估计器实现高精度的非线性接触动力学在线识别 [25]。

总之,本研究首先基于仿真数据为仿生乌龟机器人识别了一个Koopman模型。随后,利用实验数据和卡尔曼滤波实现了模型参数的在线更新。通过八字形路径跟踪仿真和方向跟踪实验,进一步验证了所提出框架的有效性。主要贡献如下:

- 提出了一种针对控制任务的 Koopman 算子建模方法。该方法在长期预测精度和跨不同参考信号及控制任务的泛化能力上明显优于基线方法。在仿真中,与基线方法相比,控制精度提高了 59.6%。设计并实现了一种结合卡尔曼滤波的在线更新机制,这增强了模型跟踪时变动态的能力。在实验数据集上,与基线方法相比,预测精度提高了 42.13%。
- 在有流动干扰的水池中进行方向跟踪的实验验证。所提出的框架在控制精度上比基线方法提高了 63.4%,同时具有更小的超调和更强的抗干扰能力。

本文结构如下:第 II 节介绍了预备知识。第 III 节阐述了基于 Koopman 理论的系统辨识算法。第 IV 节概述了数据驱动的辨识过程及后续验证。第 V 节详细说明了基于在线卡尔曼滤波的 Koopman 模型更新机制的实验实现。最后,第 VI 节给出了结论。

II. 初步工作

本节介绍了仿乌龟机器人的设计和数学建模。




图 1. 原型及坐标系。(a) 仿生乌龟机器人的原型。(b) 为两栖机器人平台建立的坐标系定义,指定了机体固定坐标系和全局惯性参考坐标系。

表 I 仿生海龟机器人技术规格

Item	Value & Description
Dimensions	$0.43 \times 1.23 \times 0.17 \text{ m}^3$
Weight	10.48 kg
Actuation Mechanism	3-DOF flippers
Sensing Modules	Camera, Pressure Sensors, Power Meter
Computing Unit	Raspberry Pi 4B (4 GB)
IMU	MPU-9250, 100 Hz sampling frequency
Servo Motors	GXYipin servo with 130 kg·cm torque
Endurance time	2 h
UWB	DW1000, accuracy error $\leq 100\text{mm}$

A. Design of the Turtle Inspired Robot

自然界中的乌龟,凭借其扁平的身体结构和强壮的鳍足,表现出卓越的运动稳定性和高效的推进能力。基于这些生物特征,我们设计了一种受乌龟启发的机器人,其原型如图1(a)所示,主要结构参数列于表I中。该机器人主要由一个中央船体和一对对称布置的三自由度仿生鳍足组成。

B. Mathematical Modeling

图1(b)说明了受乌龟启发的机器人的坐标系统。受乌龟启发的机器人的动力学方程可以表示如下:

$$M(q)\dot{\mu} + C(\mu)\mu + D(\mu)\mu + g(q) = J^T F + S_a \tau \quad (1)$$

其中 q 表示广义坐标, μ 表示广义速度。矩阵 $M(q)$ 、 $C(\mu)$ 和 $D(\mu)$ 分别表示系统惯性矩阵、科氏力和离心力矩阵以及水动力阻尼矩阵。向量 $g(q)$ 、 F 和 τ 分别表示重力和浮力/力矩、外部力/力矩以及广义力矩输入。 J 表示作用点 F 的雅可比矩阵。选择矩阵 S_a 表示对 τ 执行的操作。

考虑到该机器人在纵向横向 (x - y) 和平面纵向垂直 (x - z) 上表现出双侧对称,因此可以忽略前后、横向和平移的耦合运动。在运动过程中,海龟利用其前肢作为主要推进机制,而后肢用于方向控制。基于这一仿生原理和工程简化目标,并参照近期研究 [26],我们确定在平面运动中仅需对前后运动和偏航进行主动控制。因此,(1) 可以简化为一个水平面参数化水动力模型,该模型包含附加质量以及线性和非线性阻尼。

效果:

$$\begin{aligned}\dot{x} &= u \cos \psi - v \sin \psi \\ \dot{y} &= u \sin \psi + v \cos \psi \\ \dot{\psi} &= r \\ \dot{u} &= \frac{1}{m-X_{\dot{u}}} [X_u u + X_{u|u}|u| + \tau_X] \\ \dot{v} &= \frac{1}{m-Y_{\dot{v}}} [-(m-X_{\dot{u}})ur + Y_v v + Y_{v|v}|v|] \\ \dot{r} &= \frac{1}{I_{zz}-N_{\dot{r}}} [(X_{\dot{u}}-Y_{\dot{v}})uv + N_r r + N_{r|r}|r| + \tau_N]\end{aligned}\quad (2)$$

这里, x, y 和 ψ 指空间配置, 而 u, v 和 r 表示在机体附着坐标系中的速度分量。 $X_{\dot{u}}, Y_{\dot{v}}$ 和 $N_{\dot{r}}$ 用于量化附加质量效应, 而 X_u, Y_v 和 N_r 对应线性阻尼系数。二次阻尼项 $X_{u|u}, Y_{v|v}$ 和 $N_{r|r}$ 捕捉非线性水动力阻力。控制输入 τ_X 和 τ_N 分别控制纵向推进和偏航力矩, m 表示总质量, I_{zz} 为垂直轴转动惯量。所有水动力系数均通过 CFD 模拟获得, 数值和详细过程见参考文献 [14]。

C. Model Predictive Control

在每个采样时刻 t , 模型预测控制 (MPC) 解决以下在预测时域长度为 N 的有限时域最优控制问题:

$$\begin{aligned}\text{minimize} \quad & \sum_{k=0}^{N-1} \ell(\chi_{t+k|t}, \tau_{t+k|t}), \\ \text{subject to} \quad & \chi_{t+k+1|t} = \chi_{t+k|t} + \Delta t \cdot f(\chi_{t+k|t}, \tau_{t+k|t}), \\ & k = 0, \dots, N-1, \\ & \chi_{t|t} = \chi(t), \\ & \tau_{t+k|t} \in \mathcal{X}, \quad k = 0, \dots, N-1, \\ & \chi_{t+k|t} \in X, \quad k = 0, \dots, N-1,\end{aligned}\quad (3)$$

其中 $f(\chi, \tau)$ 表示连续时间动力学, $\tau \in \mathbb{R}^2$ 和 $\chi \in \mathbb{R}^6$ 分别是控制输入和状态, $\ell(\chi, \tau)$ 定义为:

$$\begin{aligned}\ell(\chi, \tau) &= Q_\psi (\psi - \psi_{ref})^2 + \tau^T R \tau \\ &+ (\tau - \tau_{prev})^T R_\Delta (\tau - \tau_{prev})\end{aligned}\quad (4)$$

使用以下权重矩阵和参数: $Q_\psi = 100$, $R = \text{diag}(1, 1)$ 和 $R_\Delta = \text{diag}(5, 1)$ 。在求解优化问题后, 只有第一个控制输入 $\tau_{t|t}$ 被应用到系统中。计算优化过程由 CasADi [27] 加速。

三、系统识别

本节介绍了基于库普曼理论的系统辨识方法及其通过卡尔曼滤波器的在线实现。

A. The Koopman Operator

库普曼算子随着动力学的流推动状态的测量函数。库普曼算子 $\mathcal{K}_t$ 是一个作用于本征函数 ξ 的无限维线性算子, 其作用为:

$$\mathcal{K}_t \xi = \xi \circ F_t \quad (5)$$

其中 $\circ$ 是组合运算符, t 指时间步长, F_t 表示一个连续映射函数。

使用扩展动态模态分解 (EDMD) 方法[9], 首先选择必要的观测量来构建一个有限维空间, 然后从数据中提取特征值, 从而获得一个有限维的近似线性模型。需要注意的是, 该模型并非唯一, 其具体形式完全取决于观测量的选择。

通常, 可观测量的选择主要包括三个组成部分: 系统状态、输入及其相关函数。在多步预测问题中, 为了避免引入不必要的复杂性, 系统状态与输入之间的耦合函数通常不被视为独立的可观测测量。基于这一原理, 系统的演化过程可以表述为:

$$f[k+1] = \Theta^T \cdot f[k] \quad (6)$$

其中 $f[k]$ 是观测向量, Θ^T 表示需要从数据中确定的系数矩阵

系统识别的核心目标是最小化拟合误差, 这可以用数学形式表示为在所有数据上最小化拟合误差的 L^2 范数。

$$\min_{\Theta} \sum_{k=1}^K \|\Theta^T \cdot f[k] - f[k+1]\|_2^2 \quad (7)$$

可以通过奇异值分解 (SVD) 等方法求解此最小二乘问题, 从而建立非线性系统的线性Koopman近似模型。

路径跟随是移动机器人一个常见的任务, 其中视线 (LOS) 方法广泛应用于欠驱动系统, 因为它能够通过路径点生成期望航向角, 从而降低控制复杂性 [4]。航向自由度被选择作为控制切入点, 主要基于以下两个原因: 首先, 在LOS框架下, 仅通过控制航向自由度即可实现路径跟随; 其次, 与航向自由度对应的关键状态变量——包括航向角 ψ 和转向速率 r ——可以直接从单个IMU传感器获取。

基于以上考虑, 本信主要关注控制系统设计中的航向自由度。为了构建系统状态观测框架, 当前时间步的状态向量、控制输入和参考信号分别定义为 $\chi[k] = (\chi_x[k], \chi_y[k], \chi_\psi[k], \chi_u[k], \chi_v[k], \chi_r[k])^T \in \mathbb{R}^6$, $\tau_N[k] \in \mathbb{R}$, 以及 $\zeta[k] \in \mathbb{R}$ 。这里, $\chi_x[k], \chi_y[k]$ 表示平面位置, $\chi_\psi[k]$ 为航向角, $\chi_u[k], \chi_v[k], \chi_r[k]$ 表示前进、横向和偏航速度。随后, 提升的可观测函数向量 $f[k]$ 构建如下:

$$f[k] = \begin{bmatrix} \chi_x[k], \chi_y[k], \chi_\psi[k], \chi_u[k], \chi_v[k], \chi_r[k], \\ \varepsilon[k], \chi_r[k]^2, \tau_N[k], \tau_N[k]^2 \end{bmatrix} \in \mathbb{R}^{10} \quad (8)$$

其中 $\varepsilon[k] = \zeta[k] - \chi_\psi[k]$ 是跟踪误差。与径向基函数 (RBFs) 或单项式等通用基函数相比, 所提出的提升函数是专门针对系统的控制目标和激励特性设计的。这种设计提高了Koopman模型的预测准确性和可解释性, 同时不会引入不必要的复杂性或过拟合风险。

B. Online Identification Algorithm Based on the Kalman Filter

在时间可变系统中, (6)中的系数矩阵 Θ 随时间变化。传统状态估计方法通常假设模型参数为常数, 并采用卡尔曼滤波器进行状态估计。假设传感器获取的系统状态 $\chi[k+1]$ 足够精确, 卡尔曼滤波器能够在噪声条件下基于观测数据对参数矩阵 Θ 实现最优估计, 即从 $\chi[k+1]$ 构建的函数 $f[k+1]$, 从而完成在线参数辨识。卡尔曼滤波器的设计目标是最小化后验估计误差的平方, 这与在线辨识的优化目标一致。按照参考文献 [18] 的方法, 为每个方程构建一个独立的卡尔曼滤波器, 以实现并行在线辨识。预测模型和观测函数如下:

$$\text{Prediction: } \vartheta_i[k+1] = \vartheta_i[k] \quad (9)$$

$$\text{Observation: } f_i[k+1] = \vartheta_i^T[k+1]\mathbf{f}[k] \quad (10)$$

其中 ϑ_i 是 Θ 中的系数向量, $i = 1, \dots, N$, N 是关于系统状态的变量。一般来说, Θ 变化缓慢, 并且可以在一个时间步内认为是常数。因此, 基于卡尔曼滤波器的在线系统辨识可以完成如下:

$$\vartheta_i[k+1|k] = \vartheta_i[k|k] \quad (9a)$$

$$P_i[k+1|k] = P_i[k|k] \quad (9b)$$

$$K_i[k+1] = \frac{P_i[k+1|k]\mathbf{f}[k+1]}{\mathbf{f}^T[k+1]P_i[k+1|k]\mathbf{f}[k+1] + R_i[k]} \quad (9c)$$

$$e_i[k+1] = f_i[k+1] - \vartheta_i^T[k+1|k]\mathbf{f}[k] \quad (9d)$$

$$\vartheta_i[k+1|k+1] = \vartheta_i[k+1|k] + K_i[k+1]e_i[k+1] \quad (9e)$$

$$P_i[k+1|k+1] = (I - K_i[k+1]\mathbf{f}^T[k+1])P_i[k|k] \quad (9f)$$

其中 P_i 是协方差矩阵, K_i 表示卡尔曼增益向量, R_i 指方差, e_i 表示预测误差。为了应对实际环境中噪声统计量的时变特性, 采用了一种自适应策略。过程噪声协方差 Q 和测量噪声协方差 R 初始通过离线数据进行调节; 在在线运行过程中, R 基于创新协方差递归估计, 而 Q 则根据预测误差的趋势动态调整, 从而保持最优估计性能。Koopman 模型参数 Θ 的完整更新过程在算法 1 中提供的伪代码中详细说明。

IV. 离线库普曼模型识别

本节概述了利用库普曼算子理论, 对仿生海龟机器人进行数据驱动的动态模型识别及随后验证的过程。

A. Data Collection and System Identification

用于动态模型识别的数据驱动方法对数据质量要求很高。为了满足这一要求, 本研究利用动态模拟器 Webots 获取仿生海龟机器人的高精度运动数据。为了生成一个

算法 1: 通过在线 Koopman 模型识别

Kalman Filter.

Require: Offline identified parameters $\vartheta_i[0]$, experimental data from MPC tracking, forgetting factor λ , scaling factor α , adjustment period L , bounds $[Q_{\min}, Q_{\max}]$

Ensure: Updated Koopman model parameter matrix Θ

```

1: Initialize  $P_i[0] \leftarrow I, Q \leftarrow Q_0, R \leftarrow R_0, \mathbf{f}[0], S_{\text{innov}}[0] \leftarrow \mathbf{0}$ 
2:  $K_T \leftarrow$  total time steps,  $N \leftarrow 10$ 
3: for  $k = 0$  to  $K_T - 1$  do
4:   Read new measurements  $\chi[k+1], \zeta[k+1], \tau[k+1]$ 
5:   Compute  $\varepsilon[k+1] \leftarrow \zeta[k+1] - \chi_\psi[k+1]$ 
6:   Construct  $\mathbf{f}[k+1] \leftarrow (8)$ 
7:   Innovation:  $\nu[k+1] \leftarrow \mathbf{y}[k+1] - \hat{\mathbf{y}}$ 
8:   Update innovation covariance:  $S_{\text{innov}}[k+1] \leftarrow \lambda S_{\text{innov}}[k] + (1 - \lambda)\nu[k+1]\nu[k+1]^T$ 
9:   Adapt measurement noise:  $R \leftarrow \alpha \text{diag}(S_{\text{innov}}[k+1])$  (if  $k < 10$ , keep  $R = R_0$ )
10:  for  $i = 1$  to  $N$  do
11:    Kalman filter update for  $\vartheta_i$  using 9
12:    Update  $\Theta[:, i]$ 
13:  end for
14:  Periodic  $Q$  adaptation: if  $\text{mod}(k+1, L) = 0$ , compute recent error trend  $\Delta e$ ; if  $\Delta e > \delta$ ,  $Q \leftarrow \min(\beta Q, Q_{\max})$ ; if  $\Delta e < -\delta$ ,  $Q \leftarrow \max(\gamma Q, Q_{\min})$ .
15:   $\mathbf{f}[k] \leftarrow \mathbf{f}[k+1]$ 
16:  for  $i = 1$  to  $N$  do
17:     $\vartheta_i[k|k] \leftarrow \vartheta_i[k+1|k+1]$ 
18:     $P_i[k|k] \leftarrow P_i[k+1|k+1]$ 
19:  end for
20: end for
```

为了充分激发系统的动态特性, 设计了路径跟随任务和航向角跟踪任务。具体任务如图2(a)所示。

使用该数据集, 通过求解 (7) 中描述的最小二乘问题并使用 (8) 中定义的提升函数, 识别出一个离线 Koopman 模型。为了验证模型的开环预测精度, 选择具有代表性的水平8字形路径作为验证集。作为对比基准, 第III节 (2) 中给出的动态模型参数也使用相同数据集并遵循与参考文献 [28] 一致的策略, 通过最小二乘方法直接识别。最后, 在图3中展示了参数化 CFD 模型、最小二乘识别模型和 Koopman 模型的开环航向角预测的比较分析。在 Koopman 模型中, 参考信号作为外部输入, 而基线方法仅由初始状态和控制输入驱动。

此外, 为了全面评估模型的泛化能力, 对四个预测集的航向角变化进行了预测, 包括水平排列的“8”字形路径, 结果如图3(c)所示。比较表明, 所提出的 Koopman 模型的预测精度显著高于另外两个基线模型。例如, 在预测心形轨迹的航向角时, 平均值




图2. 基于 Koopman 算子的 Sim2Real 转移框架。(a) 从仿真数据进行的离线 Koopman 模型识别。(b) 实验装置用于真实世界数据采集。位置数据可以通过各种传感器获取，例如用于地表应用的 GPS 或用于水下定位的声学设备。在本信中，为了实验装置的便利，使用了相机。(c) 通过实验数据和卡尔曼滤波器进行 Koopman 模型的在线更新。




图3. 离线模型精度分析。(a) 图八路径跟踪中不同识别模型的航向角预测比较。(b) 相应模型的航向角预测误差比较。(c) 不同数据类型的航向角预测误差比较，误差棒由五次仿真试验计算得出。提出的模型：Koopman 模型。基线 1：CFD 参数模型。基线 2：最小二乘识别模型。

Koopman 模型的预测误差仅为 0.1883 弧度，这显著低于基于 CFD 的参数模型的 1.3778 弧度和最小二乘识别模型的 1.4632 弧度。

结果表明，只有 Koopman 模型能够准确识别机器人运动过程中偏航角的突变，并令人满意地跟踪其变化趋势。相比之下，基于参数 CFD 的模型和最小二乘识别模型的预测变化更加平滑，这表明它们在捕捉系统运动的动态瞬态方面存在困难。

B. Validation of the Generalization Capability

为了有效验证所提出的方法是否编码了受乌龟启发的机器人的基本动态行为，并且




图4. 泛化能力验证。(a) 所提方法与基线方法在数字八字路径跟踪中的轨迹对比。(b) 在随机参考信号下，所提方法与基线方法的MPC跟踪误差小提琴图对比。(c) 所提方法与基线方法对不同控制器生成轨迹的预测对比，误差棒由五次仿真试验计算得出。(d) 在不同预测时间范围内，所提方法与基线方法的跟踪误差对比，误差棒由五次仿真试验计算得出。所提方法：Koopman模型。基线1：CFD参数化。基线 2：最小二乘识别模型。

模型。基线 2：最小二乘识别模型。

为了在不同的参考输入和控制律下实现良好泛化，如图4所示进行了仿真分析。在相同的控制框架和参数设置下，所提出方法的跟踪轨迹更加平滑；定量分析显示，其平均横向跟踪误差为 0.0220 m，显著低于参数化 CFD 模型的 0.545 m 误差，精度提高了 59.6%。

遵循伪随机二进制序列 (PRBS) 的原理，我们生成了多样的参考信号，并使用相同的 MPC 控制器对其进行跟踪。结果显示四分位间距更窄，误差分布更集中，这表明 Koopman 模型捕捉到了内在特性

动态特征,而不是记忆特定参考的行为,如图4(b)的小提琴图所示。为了进一步评估在不同控制器下的泛化能力,我们使用学习到的Koopman模型来预测机器人在两种未见控制策略下的运动:PID控制和滑模控制(SMC)。如图4(c)所示,该方法在这两种情况下都保持了较高的预测性能,验证了该模型并没有对特定控制器过拟合,而是捕捉到了机器人系统的潜在开环动力学。

为了分析模型长期预测精度对控制器的影响,本文考察了在不同预测时域下,所提出方法与基线方法的路径跟踪精度,结果如图4(d)所示。所提出方法的平均横向跟踪误差始终稳定在约0.018米,表明误差随预测时域的延长并未显著累积。相比之下,对于基线方法,当 N 从5增加到10时,跟踪误差显著上升,直接反映了随着预测时域扩大,模型不匹配加剧了误差,从而降低了MPC的控制性能。

V. 在线 Koopman 模型更新

本节详细说明了基于卡尔曼滤波器(KF)的Koopman模型在线更新机制的实验实现。

A. Experiment Setup and Online Model Update

模拟数据往往无法完全捕捉现实世界的复杂性,尤其是环境干扰(如波浪和流动)对机器人动力学的影响。为了解决这一问题并实现高精度模型的快速获取,本研究引入了一种基于从模拟数据建立的先验模型的在线更新机制。

实验装置如图2(b)所示。机器人的姿态是通过多传感器融合获得的:固定在水池上方的俯视相机提供位置坐标,通过微分从中推导速度;机载惯性测量单元(IMU)直接测量偏航角和偏航角速率。为了评估在线更新模型的实时预测能力,我们采用一步预测来测试模型性能。主要目标是确定在线更新后的最终模型是否优于原始离线模型。选择递归最小二乘(RLS)算法作为对照基准。该方法通过数学变换递归地实现参数更新。相比之下,本研究采用的基于卡尔曼滤波器的更新方法本质上是最小化后验估计误差。

如算法1和图2(c)所示,执行了在线参数更新。结果如图5(a)所示。通过卡尔曼滤波器更新的模型响应迅速,并能紧密追踪系统的动态变化。相比之下,原始的离线模型和使用RLS更新的模型表现出跟踪迟缓和响应不足。如图5(b)的对数刻度跟踪误差图所示,所提出的基于卡尔曼滤波器的更新方法实现了显著较小的平均预测误差,为0.0328 rad,而RLS方法为0.0566 rad,离线模型为0.0988 rad。在本研究中,收集了五组方向跟踪数据。平均




图5. 在线模型精度分析。(a) 多模型对航向跟踪一步预测的比较。(b) 偏航跟踪误差的对数尺度比较。(c) 五个实验数据集上各种模型的在线平均预测误差,误差线表示标准误差。(d) 选定的实验快照。提出模型:Koopman模型+KF。基线3:离线Koopman模型。基线4:Koopman模型+RLS。




图6. Key Koopman模型参数的在线更新比较

S.

预测误差如图5(c)所示。与RLS方法相比,所提出的框架将预测精度提高了42.13%。选定的实验快照如图5(d)所示。

此外,图6展示了在偏航角跟踪任务中关键模型参数(ψ 和 τ)的时间变化。图中显示,卡尔曼滤波方法对参数进行了更为显著的更新,并且参数值更快地收敛到稳定状态。这进一步验证了卡尔曼滤波方法在动态环境中能够快速收敛并稳定估计模型参数的有效性。

B. Verification With MPC in Experiment

为了评估模型在扰动条件下的性能,本研究通过在水箱中进行实验并进行布置

表 II 提出的框架消融研究

Architecture	MAE (rad)	RMSE (rad)	MaxAE (rad)	STD (rad)	90% Percentile Error (rad)
Full Proposed	0.0328	0.0438	0.1346	0.0292	0.0723
Least Square + Sim2Real + KF	0.0581	0.0675	0.1666	0.0344	0.0992
Koopman + RLS	0.0566	0.0756	0.2487	0.0502	0.1229
Offline Koopman	0.0988	0.1402	0.4534	0.0986	0.2408




图7. 乌龟仿生机器人在执行方向跟踪任务时航向角的变化。提出方法：采用在线更新的Koopman模型的MPC；基准5：采用离线Koopman模型的MPC；基准6：采用CFD参数模型的MPC。

螺旋桨用于产生可控的流动扰动，从而模拟在现实运行条件下遇到的不确定动力学。为了确保不同动态模型之间的可比性，在一致的控制参数设置下，基于MPC的姿态跟踪比较实验已被执行。

实验结果如图7所示。与CFD参数模型相比，无论是离线Koopman模型还是在线Koopman模型在流动扰动下均表现出更低的超调，并展示了更好的姿态保持性能。其中，所提出的在线Koopman模型进一步提高了跟踪稳定性，表明其在捕捉仿真中未建模动力学方面的有效性。在稳态跟踪阶段，所提出的方法实现了0.0164 rad的均方根误差（RMSE），低于离线Koopman模型的0.0294 rad和CFD参数模型的0.0448 rad。与基线方法相比，所提出方法的跟踪误差降低了63.4%，验证了在线更新机制在提高模型预测精度和扰动抵抗能力方面的有效性。图8展示了实验过程中机器人运动姿态的序列，从视觉上显示了其运动特征。

C. Ablation Study

表 II 中呈现的消融研究结果定量地展示了所提出框架中每个组件的贡献。表 II 中的数据是五次试验的平均值




图8. 乌龟灵感机器人在方向追踪任务中的实验快照。

实验运行中，选择的评估指标包括平均绝对误差（MAE）、均方根误差（RMSE）、最大绝对误差（MaxAE）、误差标准差（STD）以及90%百分位误差。首先，在线自适应的必要性通过事实得到证明：使用RLS更新的Koopman模型明显优于离线Koopman模型，这表明仅靠仿真数据无法完全捕捉真实世界的动态。其次，全流程提议方法验证了卡尔曼滤波器作为在线更新机制的优越性，该方法在所有指标上均达到最低误差（MAE 0.0328, RMSE 0.0438），超过了Koopman-RLS变体。最后，通过将全流程提议方法与最小二乘识别模型进行比较，凸显了Koopman提升的重要性：尽管两者都采用Sim2Real预训练和卡尔曼滤波，基于Koopman的架构仍产生显著更低的预测误差（例如，MAE 0.0328 对比 0.0581）。这些比较表明

六、结论

在这封信中，我们提出了一种基于库普曼算子的在线系统识别方法，并将其整合到Sim2Real迁移框架中，该方法已成功应用于受海龟启发的机器人系统的流体动力建模。基于卡尔曼滤波器设计的在线算法能够利用有限的真实实验数据，对离线训练的先验模型进行快速且精确的在线更新，有效捕捉动态环境中系统的时变特性。实验结果表明，所提出的库普曼模型在偏航运动预测和控制任务中均优于传统的参数化CFD模型和最小二乘识别方法，同时保持了强

即使在螺旋桨产生的干扰下，也能保持稳健性和跟踪精度。此外，通过采用Sim2Real迁移策略，我们显著减少了对大量真实运动数据的依赖，并增强了数据驱动建模在实验条件有限的场景中的适用性。

未来的工作将集中于依赖于速度和误差状态的、平移不变的库普曼模型公式化。

参考文献

- [1] K. Melo, T. Horvat, 和 A. J. Ijspeert, “非洲荒野中的动物机器人：经验教训与野外机器人展望,” *Sci. Robot.*, 第8卷, 第85期, 2023年, 文章编号 eadd8662. [2] R. Baines 等, “通过自适应形态发生的多环境机器人过渡,” *Nature*, 第610卷, 第7931期, 页283–289, 2022年. [3] R. Wang 等, “由嵌入感知的仿生肌肉驱动的软体机器人鱼, 实现自适应多模式游泳,” *IEEE Trans. Robot.*, 第41卷, 页1329–1345, 2025年. [4] T. Salumäe, A. Chemori, 和 M. Kruusmaa, “悬浮仿生四鳍水下机器人的运动控制,” *IEEE J. Ocean. Eng.*, 第44卷, 第1期, 页54–71, 2019年1月. [5] X. Li, Q. Ren, 和 J.-X. Xu, “通过迭代学习控制实现机器人鱼的精确速度跟踪,” *IEEE Trans. Ind. Electron.*, 第63卷, 第4期, 页2221–2228, 2016年4月. [6] Z. Wu, J. Yu, J. Yuan, 和 M. Tan, “面向滑翔的机器人海豚：设计、建模与实验,” *IEEE/ASME Trans. Mechatron.*, 第24卷, 第1期, 页260–270, 2019年2月. [7] R. Wang, S. Wang, Y. Wang, L. Che [14] A. Liu 等, “一种用于动态地形适应的视觉-触觉融合智能仿生两栖乌龟机器人,” *IEEE Trans. Robot.*, 第41卷, 页6345–6363, 2025. [15] S. H. Rudy, S. L. Brunton, J. L. Proctor, 和 J. N. Kutz, “基于数据发现偏微分方程,” *Sci. Adv.*, 第3卷, 第4期, 2017, 文章号 e1602614. [16] S. L. Brunton, J. L. Proctor, 和 J. N. Kutz, “通过非线性动力系统稀疏识别从数据中发现控制方程,” *Proc. Nat. Acad. Sci.*, 第113卷, 第15期, 页3932–3937, 2016. [17] Y. Li 和 Z. Liu, “软体机器人基于数据的预测追踪控制：一种结合可变结构低阶扩展状态观测器和卡尔曼滤波器的 Koopman-MPC 框架,” *Nonlinear Dyn.*, 页1–23, 2025. [18] X. Guan, Y. Wang, X. Kang, W. Yao, J. Zhang, 和 G. Li, “用于球形机器人的在线系统识别算法, 基于 Koopman 理论,” *IEEE Robot. Automat. Lett.*, 第10卷, 第5期, 页4644–451, 2025年5月. [19] D. Bruder, X. Fu, R. B. Gillespie, C. D. Remy