

神经内模控制：通过预测误差反馈学习鲁棒控制策略

高峰¹, 余超^{1,3†}, 王宇¹, 吴毅^{1,2†}

摘要——在复杂环境中面对扰动时实现精确运动控制，仍然是机器人领域的一项重大挑战。经典的基于模型的方法往往难以处理非线性特性和非结构化扰动，而基于强化学习（RL）的方法在遇到未见过的场景时可能表现脆弱。本文提出了一种新颖的框架——神经内模控制（NeuralIMC），该框架结合了基于模型控制与基于强化学习的控制，以增强鲁棒性。我们的框架通过应用刚体动力学的牛顿-欧拉方程来简化预测模型，从而无需捕捉复杂的高维非线性特性。该内模将无模型强化学习算法与预测误差反馈相结合。这种设计构建了一种闭环控制结构，从而提升了控制系统的鲁棒性和泛化能力。我们在四旋翼飞行器和四足机器人上验证了该框架的有效性，结果显示其性能优于当前最先进的方法。此外，在挂载绳索负载的四旋翼飞行器上的实际部署，进一步凸显了该框架在“仿真到现实”（sim-to-real）迁移过程中的鲁棒性。我们的代码已发布于 <https://github.com/thu-uav/NeuralIMC>。




图1：预测误差可能由系统建模不匹配和/或外部扰动引起。

关键词——鲁棒控制，强化学习，感觉运动学习

I. 引言

在复杂且存在干扰的环境中实现稳定、精确的运动，对于各类机器人至关重要——例如在风场中保持稳定飞行的四旋翼飞行器，以及在多样化地形上负重前行的足式机器人。这一挑战通常被称为鲁棒控制或自适应控制问题，并已得到广泛研究

[1]。经典的自适应控制方法通过实时调整控制参数来补偿动态环境变化，通常依赖于系统及扰动的数学模型

[2]、[3]、[4]、[5]；而鲁棒控制方法（如内模控制

[6]）则利用更具信息量的信号来增强系统的鲁棒性。尽管这些方法能保证稳定性，但它们依赖于对系统动力学的精确建模，而对于存在非结构化扰动的非线性系统而言，这种建模极具挑战性。相比之下，强化学习（RL）方法在各种形态机器人的连续控制任务中展现出了卓越的成效，涵盖了机械臂机器人的技能学习 [7]、[8]、高速四旋翼竞速 [9]、[10]

以及足式机器人的自适应运动控制

[11]、[12]、[13]、[14]、[15]。

通过在随机化的动力学和环境参数下进行大规模训练，基于强化学习的控制方法能够实现跨不同条件和环境的泛化 [16]、[17]，使机器人即使在未曾见过且高度多变的场景中也能可靠地执行任务。近期，将基于模型的控制与基于强化学习（RL）的神经控制相结合，以融合两者优势，已成为一种趋势 [18]、[19]、[13]、

[20]。一种具有代表性的框架是利用预测的未来状态或估计的扰动作为附加输入信号，从而获得信息量更丰富的无模型强化学习策略。Long 等人 [13]

采用无监督对比表征学习来训练预测编码器，使其能够在潜在空间中估计下一时刻的状态。相比之下，Huang 等人 [20] 利用人工设计的 L1 自适应律 [21]

显式估计施加的力扰动，从而构建出一种能够应对意外风场的鲁棒轨迹跟踪控制器。尽管前景广阔，但将基于模型的控制与基于 RL

的控制相结合仍面临重大挑战。当训练数据无法覆盖真实世界的动力学特性时，预测模型往往难以应对多变量；而人工设计的扰动估计器则需要精确的参数调整，这限制了其在复杂系统中的可行性以及对动态变化的适应能力。为了建立一种更通用的方法，我们需要开发一种能有效结合这些控制方式的结构，以充分发挥各自优势并克服上述局限性。受基于模型控制的启发，本文提出了一种新的基于学习的控制方法，该方法利用预测误差反馈来增强控制鲁棒性。通过简化模型，使其专注于机器人的主体，并.....

本研究获国家自然科学基金（项目编号：62406159、62325405）、中国博士后科学基金资助项目（项目编号：GZC20240830、2024M761676）及中国博士后科学基金特别资助项目（项目编号：2024T170496）支持。†

通讯作者。{zoeyuchao,jxwuyi}@gmail.com。1 清华大学，中国北京。2 上海期智研究院，中国上海。3 北京中关村学院，中国北京。




图 2：闭环 NeuralIMC 框架，利用显式预测模型计算下一时刻的机体状态；该框架适用于四旋翼飞行器和腿式机器人。

通过将系统的动力学特性视为刚体变换，我们规避了复杂机器人系统与环境交互所带来的高维非线性问题。这种简化使我们能够使用显式预测模型，而无需进行参数调整，从而为鲁棒的闭环控制奠定了基础。我们将预测误差（定义为受控对象响应与模型响应之间的差异）作为反馈信号输入策略，通过信息丰富的反馈和大规模训练来增强系统的鲁棒性与泛化能力。如图2所示，我们的框架通过引入这一反馈回路，能够轻松地与其他学习算法集成。为了验证该方法的有效性与通用性，我们将其应用于两种主流的机器人形态：需要精确三维控制的四旋翼飞行器，以及需要在复杂地形交互中实现自适应运动的四足机器人。实验结果表明，我们的框架在这两个领域均优于当前最先进的控制方法。此外，我们还在挂载了各种绳索悬挂负载的四旋翼飞行器上进行了实地部署，以展示其在“仿真到现实”（sim-to-real）迁移过程中的鲁棒性。

II. 相关工作

A. 经典控制与扰动估计

传统的自适应控制器需要在闭环模式下估计系统参数，以便实时调整控制动作。L1自适应控制已被广泛用于估计四旋翼飞行器中的力扰动 [22], [23]。Neural-Fly [18] 引入了预训练表征，利用深度学习增强了快速在线自适应能力，从而在未曾遇到的风况下实现了稳定飞行。内模控制（IMC）[6], [3] 是一种用于鲁棒控制的通用架构，它利用预定义的模型来预测系统响应并估计扰动。然而，将IMC应用于更复杂的非线性系统极具挑战性，因为构建此类系统的可靠模型十分困难。Long等人 [13] 提出的混合内模（HIM）进一步利用了基于学习的内模，该模型采用无监督对比学习，并将学习到的模型作为预测编码器，在潜在空间中估计系统响应。尽管这些方法各具优势，但它们要么依赖于显式的扰动估计，要么在很大程度上受预测精度的影响；一旦预测精度下降，系统性能便会受到显著影响。

B. 基于学习的自适应控制

随着高并行仿真器 [17], [24], [25] 的飞速发展，强化学习（RL）方法在实现鲁棒控制方面展现出了强大的能力，应用范围涵盖四旋翼飞行器 [26], [20] 和腿式机器人 [11], [12], [13], [14], [15] 等。与传统的基于模型的控制不同，这些基于学习的方法通常采用无模型强化学习算法（如 PPO [27]），在大规模随机环境中训练神经控制器。Koryakovskii 等人 [28] 提出引入基于强化学习的策略来生成残差动作，从而在模型不匹配的情况下对非线性模型预测控制进行补偿。Rapid Motor Adaptation (RMA) [12] 是一种纯粹基于强化学习的方法，它通过“教师-学生”训练流程，利用状态-动作历史数据在潜在空间中预测环境参数。该方法已被推广应用于四旋翼飞行器 [26]、双足机器人 [29] 和人形机器人 [15]。一项后续研究发现，利用短期和长期输入/输出历史信息的双重历史架构，仅需简单的单阶段训练过程即可实现卓越性能 [14]。相比之下，DATT [20] 引入了 L1 自适应律 [21] 来直接估计作用于四旋翼飞行器的力，并将这些力作为策略的输入。CAL [28] 则通过利用强化学习（RL）生成残差动作来增强非线性模型预测控制（NMPC）的输出，从而将 RL 与 NMPC 结合起来。尽管 DATT 和 CAL 在经过精确参数调整后均被证明有效，但它们对经典控制组件中的人工设定参数较为敏感，这限制了其在更复杂系统中的泛化能力。

III. 方法

本节介绍一个通用框架，该框架通过一种名为 NeuralIMC 的简化预测模型，架起了基于模型控制与基于 RL 控制之间的桥梁。我们首先介绍内模控制（IMC）的基本原理，以及我们将其与基于 RL 的神经控制相结合的扩展方案（第 III-A 节）。通过采用无模型 RL 算法 PPO [27]，我们降低了传统基于模型控制通常所要求的复杂度和精度标准。接下来，我们详细阐述如何利用刚体变换来预测机器人机体状态，从而建立一种通用方法来估计扰动并将其纳入控制策略（第 III-B 节）。最后，我们说明该框架在……中的应用。




图3：经典反馈控制与内模控制（IMC）的反馈结构。

两种特定的机器人形态：四旋翼飞行器和四足机器人（第III-C节）。

A. 内模控制

内模控制（IMC）是一种鲁棒控制框架，在处理模型不确定性和扰动方面优于传统的反馈控制。与实时纠正误差的反馈控制不同，IMC 利用预测模型来预判并补偿扰动。图 3 展示了它们的结构，其中 P 和 $\tilde{P}$ 分别代表被控对象（plant）和内模， Q 是 IMC 控制器， C 是传统反馈控制器； r 、 d 和 y 分别表示参考信号、扰动和输出。IMC 计算预测响应与实际响应之间的差值 $\tilde{d} = \tilde{y} - y$ ，并据此调整控制输入以增强鲁棒性。当被控对象易于建模时 [3]，IMC 的应用较为简单直观；但在非线性系统中，若近似模型无法捕捉真实的动态特性 [30], [31]，IMC 的应用则面临挑战。这种对精确模型的依赖限制了其在机器人领域的应用，例如携带悬挂负载的四旋翼飞行器或在复杂地形上行走的足式机器人，因为这些场景下的系统精确建模十分困难。为了应对这些挑战，我们的方法将 IMC 与大规模强化学习（RL）训练相结合。简化的预测模型提供了一个粗略但稳定的估计，而大规模随机化仿真则用于训练鲁棒的控制策略，以补偿建模误差。RL 利用预测误差反馈来优化策略，从而揭示外部扰动和非线性动态特性，实现更具适应性和有效性的实际场景控制。

B. 简化预测模型的设计

预测模型是我们框架的核心，它实现了偏差检测与补偿功能。该模型的设计面临两大挑战：准确估计系统响应，以及确保预测结果与实际行为高度一致。精确估计确保了反馈回路能够反映机器人的真实状态，而对齐则保证了系统在各种工况下的可靠性。

为了简化不同机器人之间的状态估计流程，我们仅对刚体状态进行建模，而不包含特定于执行器或肢体的状态。对于配备单目或双目相机及内置惯性测量单元（IMU）的机器人，许多视觉（或视觉惯性）里程计方法都能提供鲁棒的状态估计 [32], [33], [34], [35]；这些估计结果可用作IMC架构中的实际系统响应。通过将机器人视为刚体并利用欧几里得变换来估计下一时刻的状态，我们显著降低了建模复杂度，从而提高了实用性与效率。在此，我们首先介绍构建预测模型及计算误差的通用方法，随后在下一节针对不同机器人构型给出具体的适配方案。我们假设模型输入包含速度或加速度指令，并将当前的机体状态定义为 $x_k = [p_k, q_k, v_k, \omega_k] \in \mathbb{R}^{13}$ ，其中 p_k 为位置， q_k 为四元数（表征姿态）， v_k 为速度， ω_k 为角速度。两个时间步长之间的时间间隔记为 t 。机体的下一时刻位置与速度可通过牛顿定律 [36] 计算得出：

$$\tilde{p}_{k+1} = p_k + v_k \Delta t + \frac{1}{2} a_k \Delta t^2, \quad (1)$$

$$\tilde{v}_{k+1} = v_k + a_k \Delta t. \quad (2)$$

针对旋转，我们采用离散更新规则，同时处理奇异性问题。首先，利用角速度 ω_k 和角加速度 $\dot{\omega}_k$ 计算角度变化量 θ ：

$$\Delta \theta = \omega_k \Delta t + \frac{1}{2} \dot{\omega}_k \Delta t^2. \quad (3)$$

接下来，参考 [37] 的方法，应用指数映射将旋转从 $\mathbb{R}^3$ 空间投影至 $SO(3)$ 空间，从而获得相应的四元数 $q_{\Delta \theta}$ ：

$$q_{\Delta \theta} = \begin{cases} \left[\cos\left(\frac{\|\Delta \theta\|}{2}\right), \frac{\sin\left(\frac{\|\Delta \theta\|}{2}\right)}{\|\Delta \theta\|} \cdot \Delta \theta \right], & \|\Delta \theta\| \leq \sqrt[4]{\epsilon_{\text{machine}}} \\ \left[\cos\left(\frac{\|\Delta \theta\|}{2}\right), \left(\frac{1}{2} + \frac{\|\Delta \theta\|^2}{48}\right) \cdot \Delta \theta \right], & \text{otherwise} \end{cases} \quad (4)$$

最后，我们可以按下式预测下一时刻的四元数与角速度，其中 $\otimes$ 表示四元数乘法：

$$\tilde{q}_{k+1} = q_k \otimes q_{\Delta \theta} \quad (5)$$

$$\tilde{\omega}_{k+1} = \omega_k + \dot{\omega}_k \Delta t \quad (6)$$

我们建立了一种明确的方法来预测下一时刻的机体状态，前提是所需的运动可以用加速度或速度层级的指令来表示。随后，利用预测的机体状态 $\tilde{x}_{k+1} = [\tilde{p}_{k+1}, \tilde{q}_{k+1}, \tilde{v}_{k+1}, \tilde{\omega}_{k+1}]$ 和实际机体状态 x_{k+1} ，计算预测误差 $\tilde{d}_{k+1}$ ，并将其输入策略网络以提供有效的反馈信号。

$$\tilde{d}_{k+1} = [\Delta \tilde{p}_{k+1}, 1 - \cos \tilde{\Theta}, \Delta \tilde{v}_{k+1}, \Delta \tilde{\omega}_{k+1}] \quad (7)$$

其中， $\tilde{p}_{k+1}$ 、 $\tilde{v}_{k+1}$ 和 $\tilde{\omega}_{k+1}$ 分别表示位置、速度和角速度的差值。我们采用余弦距离来量化姿态间的差异，其中 $\tilde{\Theta}$ 为两个四元数之间的角度差。

表 I：四旋翼飞行器动力学随机化参数范围。 $K_0 p = [37, 37, 11]$

参数名称	训练范围	评估范围
质量 (M)	[0.142, 0.950]	[0.114, 1.140]
臂长 (L)	[0.046, 0.200]	[0.037, 0.240]
宽长比 (aw)	[1.0, 1.414]	[0.852, 1.732]
高长比 (ah)	[0.577, 1.0]	[0.268, 1.414]
电机力常数 (Kf)	[1.15e-7, 7.64e-6]	[9.16e-8, 9.17e-6]
最大推重比	[2.0, 3.5]	[1.6, 4.2]
电机阻力常数 (κ)	[0.0041, 0.0168]	[0.0033, 0.0201]
电机时间常数 (τ_c)	[0.3, 0.5]	[0.24, 0.6]
P增益 (Kp)	[-0.3, 0.3]	$\times K_0 p$
$\times K_0 p$	[-0.5, 0.5]	$\times K_0 p$

C. 常见机器人规格

本节将进一步阐述如何针对各类机器人（包括四旋翼飞行器和四足机器人）推导速度或加速度指令。我们将展示这些指令如何与现有的控制方法相契合，从而确保其能无缝集成到策略学习过程中。1) 四旋翼飞行器：传统的四旋翼控制器采用级联结构 [38]，这使得神经控制器能够灵活地集成其中。近期研究表明，采用总推力（collective thrust）和机体角速度（bodyrate，即 CTBR）作为动作空间，能够增强系统对动力学不匹配的适应能力，改善域迁移（domain transfer）效果，并提升机动性能 [39], [20], [9]。这种设计与我们的框架相吻合：策略输出的机体角速度指令用于更新旋转状态，而总推力则决定线性加速度。因此，基于先前的策略输出与后续机体状态计算出的预测误差，可直接整合进当前的策略输入中，而无需修改学习算法。2) 四足机器人：与四旋翼飞行器不同，腿式机器人（特别是四足和双足机器人）因其高维度的驱动特性及与地形的复杂交互，非常适合采用基于强化学习（RL）的控制方法 [8], [11], [12], [14], [19]。神经控制器通常生成执行器目标值，以实现期望的机体速度（ v_x, v_y, ω_z ）。为了将我们的预测模型集成到控制回路中，我们采用参考速度指令作为模型输入，并通过对连续指令求导来推导线加速度和角加速度。将其他加速度分量设为零，可确保与现有策略的无缝集成。该方法通过一个增强策略输入的即插即用（plug-and-play）反馈回路，能够与其他算法兼容。

IV. 实验结果

为了评估我们框架的性能与通用性，我们在四旋翼飞行器和四足机器人上进行了实验，并与各自领域内的最先进方法进行了对比。随后，我们针对简化预测模型的反馈结构及噪声容忍度进行了消融实验。最后，我们展示了该框架在挂载两个绳索悬挂负载的四旋翼飞行器上的“仿真到实物”（sim-to-real）部署结果，以此验证其在提升系统鲁棒性方面的有效性。

A. 实验设置

1) 四旋翼飞行器：针对四旋翼飞行器，控制器是在一个基于文献[40]所述动力学模型的定制仿真器中进行训练的，其中总推力（collective thrust）和机体角速率（body-rate）指令为

.....后接一个PD控制器。采用四阶龙格-库塔法（Runge-Kutta method）[41]在每个仿真步长更新四旋翼的状态，更新频率为200 Hz，而控制器的执行频率为50 Hz。参考Huang等人[20]的方法，我们在两种类型的参考轨迹上训练控制器：平滑的链式多项式轨迹和不可行的“之”字形（zigzag）轨迹。外部扰动以 $3.3 \text{ m/s}^2, 3.3 \text{ m/s}^2$ 范围内的随机力扰动形式施加，模拟[20]中所述的布朗运动变化。在训练的每个回合（episode）开始时，动力学参数会被随机化；评估时则使用未见过的参数，以测试系统的鲁棒性。详细的随机化范围见表I。我们使用五个随机种子对每种方法进行训练和评估，并报告1,024次并行试验的平均性能。在评估阶段，对于在平滑轨迹上训练的控制器，我们在两种随机生成的平滑路径（圆形和链式多项式）上进行测试；而对于在不可行路径上训练的控制器，则在五角星形和“之”字形轨迹上进行测试。2) 四足机器人：参考Long等人[13]的方法，我们使用Isaac Gym [17]为Unitree Aliengo机器人训练控制器，采用4,096个并行环境和100步的轨迹展开（rollout）。训练课程包含难度递增的地形和参考指令。控制器在金字塔形斜坡、粗糙金字塔形斜坡、楼梯以及带有离散障碍物的平坦地面等地形上进行训练，这些地形的分布比例为[0.1, 0.2, 0.6, 0.1]。我们通过跟踪x-y平面线速度或偏航角速度指令来评估各种方法，测试条件包括无扰动和随机力推力两种情况。x-y线速度指令在 $[1.0, 1.0] \text{ m/s}$ 范围内采样，偏航角速度指令在 $[1.0, 1.0] \text{ rad/s}$ 范围内采样。在线速度跟踪评估中，角速度目标设为零；反之，在角速度跟踪评估中，线速度目标设为零。在线速度跟踪任务中，前向和侧向速度均在 $[1 \text{ m/s}, 1 \text{ m/s}]$ 范围内进行均匀采样。在角速度跟踪任务中，偏航角速度（yaw rate）在 $[1 \text{ rad/s}, 1 \text{ rad/s}]$ 区间内进行均匀采样。跟踪误差的计算基于五个随机种子，每个种子对应4096个并行环境。为了验证鲁棒性，我们模拟了脉冲式推力干扰：每隔16个时间步，向机器人施加一个随机基准速度（在最大范围内均匀采样）。训练期间的最大脉冲速度为 1 m/s ，评估时增加至 1.5 m/s 。

B. 四旋翼飞行器实验

我们将针对四旋翼飞行器的方法与两种经典控制方法（L1-PID和L1-MPPI）以及四种基于学习的基准方法（CAL [28]、PPO [27]、RMA [12]、DATT [20]）进行了对比；其中RMA和DATT各使用了两种变体，以便进行更深入的分析。所有方法均采用相同的PPO训练参数。CAL [28]结合了MPPI和RL（强化学习），其中MPPI作为一种基于采样的非线性模型预测控制（MPC）方法，而RL策略则用于补偿MPPI的输出。在MPPI的采样过程中，我们将采样数量设为4096，滚动时域（rollout horizon）设为20。PPO采用三层多层感知机（MLP）策略，并利用时间卷积网络（TCN）处理参考轨迹中的未来航点（该轨迹处理方式被所有其他方法沿用）。此外，RMA采用了教师-学生训练框架，其中RMA(T)作为教师模型，而

表

II：四旋翼飞行器跟踪误差（单位：m）的仿真结果，数据为五次随机种子实验的平均值。加粗数值表示最优结果。蓝色单元格表示在随机外力扰动下的性能，括号内的百分比表示相对于静态条件下的误差变化率。T 和 S 分别指代 RMA 中的教师模型和学生模型，而带有 GT 的 DATT 表示使用真实（ground-truth）扰动输入，而非 L1 估计值。

配置 方法 平滑轨迹 不可行轨迹 圆形 链式多边形 五角星 之字形									
训练	$\mathcal{L}_1$ -PID	0.214	0.237 (+10.74%)	0.043	0.054 (+25.58%)	<i>crashed</i>		<i>crashed</i>	
	$\mathcal{L}_1$ -MPPI	0.202	0.215 (+6.44%)	0.092	0.117 (+27.17%)	0.193	0.216 (+11.91%)	0.169	0.186 (+10.06%)
	CAL	0.087	0.157 (+80.46%)	0.056	0.118 (+110.71%)	0.103	0.175 (+69.90%)	0.105	0.164 (+56.19%)
	PPO	0.102	0.169 (+65.69%)	0.065	0.117 (+80.00%)	0.097	0.172 (+77.32%)	0.095	0.154 (+62.11%)
	RMA (T)	0.071	0.080 (+12.68%)	0.043	0.047 (+9.30%)	0.087	0.094 (+8.05%)	0.074	0.082 (+10.81%)
	RMA (S)	0.084	0.110 (+30.95%)	0.048	0.064 (+33.33%)	0.116	0.157 (+35.34%)	0.112	0.142 (+26.79%)
	DATT ($\mathcal{L}_1$)	0.084	0.128 (+52.38%)	0.051	0.076 (+49.02%)	0.089	0.163 (+83.15%)	0.077	0.138 (+79.22%)
	DATT (GT)	0.084	0.093 (+10.71%)	0.052	0.055 (+5.77%)	0.089	0.098 (+10.11%)	0.077	0.084 (+9.09%)
	Ours	0.072	0.083 (+15.28%)	0.032	0.038 (+18.75%)	0.065	0.073 (+12.31%)	0.057	0.064 (+12.28%)
评估	$\mathcal{L}_1$ -PID	0.372	0.416 (+11.82%)	0.061	0.107 (+75.41%)	<i>crashed</i>		<i>crashed</i>	
	$\mathcal{L}_1$ -MPPI	0.212	0.234 (+10.38%)	0.097	0.132 (+36.08%)	0.207	0.253 (+22.22%)	0.176	0.218 (+23.86%)
	CAL	0.224	0.321 (+43.30%)	0.171	0.251 (+46.78%)	0.262	0.364 (+38.93%)	0.265	0.358 (+35.09%)
	PPO	0.265	0.351 (+32.45%)	0.183	0.273 (+49.18%)	0.257	0.374 (+45.53%)	0.265	0.367 (+38.49%)
	RMA (T)	0.117	0.147 (+25.64%)	0.072	0.097 (+34.72%)	0.151	0.192 (+27.15%)	0.145	0.187 (+28.97%)
	RMA (S)	0.280	0.360 (+28.57%)	0.174	0.243 (+39.66%)	0.358	0.424 (+18.44%)	0.349	0.417 (+19.48%)
	DATT ($\mathcal{L}_1$)	0.137	0.523 (+281.75%)	0.094	0.354 (+276.60%)	0.169	0.585 (+246.15%)	0.160	0.559 (+249.38%)
	DATT (GT)	0.139	0.167 (+20.14%)	0.094	0.119 (+26.60%)	0.178	0.197 (+10.67%)	0.156	0.189 (+21.15%)
	Ours	0.113	0.135 (+19.47%)	0.054	0.073 (+35.19%)	0.103	0.134 (+30.10%)	0.101	0.132 (+30.69%)

RMA(S) 充当学生模型。RMA(T) 整合了动态参数和真实的力干扰（ground-truth force disturbances），而 RMA(S) 则利用时间卷积网络（TCN）根据状态-动作历史来近似教师模型的潜在状态。相比之下，DATT 利用 L1 干扰估计器和跟踪误差输入来提高轨迹跟踪的鲁棒性。为了分离 L1 估计器的影响，我们还引入了一个“特权”变体 DATT(GT)，它直接使用真实的力干扰来替代估计器。如表 II 所示，我们的方法在几乎所有任务中都持续优于其他方法，特别是在存在干扰和系统动力学超出分布范围（OOD）的情况下。在基于估计器的基准方法中——无论是显式的（如 L1-PID、L1-MPPI 和 DATT 中的 L1 估计器）还是隐式的（如 RMA 的神经编码器）——DATT 表现出最强的鲁棒性，这得益于其显式 L1 估计器与基于强化学习（RL）控制器的结合。然而，所有基于估计器的方法在我们的极端 OOD 场景下（即内部动力学发生变化或出现突发外力时）性能都会急剧下降，因为此时估计器变得不可靠，控制鲁棒性也随之受损。CAL 和 PPO 等不依赖估计器的方法也无法应对这些多变的干扰。相比之下，我们的方法计算预期机体变换与观测机体变换之间的预测误差，从而直接反映状态漂移和干扰幅度。基于该误差训练出的策略在常规工况和意外工况下均能保持优异性能。我们也承认，实验中有限的超参数搜索范围可能导致了基准方法性能的下降。为了确保公平比较，我们纳入了特权变体（DATT(GT) 和 RMA(T)），它们接收真实状态而非估计值，代表了调优的性能上限。即使与这些特权方法相比，我们由预测误差驱动的控制 器仍能实现更优越、更稳定的控制，这支持了我们的假设：显式预测误差反馈提供了一条实现鲁棒性的简单且具有通用性的途径。

性能。

C. 四足机器人实验


针对四足机器人，我们将我们的方法与 PPO [27]、RMA [12] 和 HIM [13] 进行了比较。PPO 和 RMA 是四足机器人连续控制领域的标准且常用的基准方法，而 HIM 利用无监督对比学习来训练一个预测编码器，用于预测下一时刻的潜在状态和机体速度。在此，我们直接使用 RMA 的教师策略（teacher-policy）来设定一个强基准。我们的方法通过整合预测误差反馈来增强 PPO 策略。此外，我们还评估了该方法的一个变体，即在训练和评估过程中，将预测误差反馈同时加入到 HIM 策略及其预测编码器的输入中。如表 III 所示，在各种测试条件下，我们的方法性能优于 HIM 26%–44%，并能媲美甚至超越具有特权信息的 RMA。将我们的框架与 HIM 结合后，性能也较原始 HIM 有所提升。有趣的是，当与我们的 NeuralIMC 结构结合时，HIM 中的预测编码器表现出较标准 PPO 略微下降的趋势。我们推测这是因为预测误差为鲁棒控制提供了充足的信号，使得预测编码的额外影响变得微不足道。这表明，仅靠预测误差反馈就足以提供增强控制鲁棒性所需的信息，从而简化神经控制流程，并促进与其他学习算法的集成。

D. 消融实验


在本节中，我们进行了三项消融实验以分析我们的框架。受 [14] 的启发，我们首先考察了引入短时和长时输入/输出历史数据是否能提升性能。接下来，我们在预测模型的输入和输出中引入噪声，以评估其鲁棒性以及预测精度对控制的影响。最后，我们

表 III：四足机器人仿真结果，基于五个随机种子取平均值。线速度和角速度的跟踪误差分别计算为 $\|v_{x,y} - v_{target\ x,y}\|_2$ (单位：m/s) 和 $\|\omega_{yaw} - \omega_{target\ yaw}\|_2$ (单位：rad/s)。每种情况下的最佳结果均以粗体标示。

干扰方法		斜坡	粗糙斜坡	楼梯	离散障碍物	线速度	角速度	线速度	角速度	线速度	角速度	线速度	角速度
无	PPO	0.132	0.085	0.143	0.087	0.200	0.085	0.163	0.085				
	RMA	0.084	0.050	0.086	0.051	0.127	0.050	0.110	0.050				
	HIM	0.100	0.067	0.103	0.068	0.181	0.067	0.147	0.067				
	Ours (w/ HIM)	0.077	0.052	0.079	0.053	0.126	0.053	0.105	0.052				
	Ours	0.071	0.048	0.073	0.049	0.101	0.048	0.085	0.048				
脉冲	PPO	0.151	0.101	0.162	0.103	0.216	0.101	0.178	0.101				
	RMA	0.096	0.059	0.098	0.060	0.137	0.060	0.120	0.059				
	HIM	0.117	0.080	0.120	0.081	0.186	0.080	0.157	0.080				
	Ours (w/ HIM)	0.091	0.061	0.093	0.061	0.139	0.061	0.117	0.061				
	Ours	0.086	0.058	0.087	0.059	0.115	0.059	0.099	0.058				



(a) 改变短历史长度。



(b) 改变长历史长度。

图 4：针对不同历史长度的反馈结构消融研究。

将我们的方法与使用完整动力学模型的方法进行比较，以评估模型简化的效果。所有实验均涉及四旋翼飞行器在三个随机种子点上跟踪之字形轨迹。1) 历史结构：我们评估了包含历史记录的反馈结构。在短历史实验中，我们将最近的输入/输出对（包括预测误差）连接成一个输入向量。对于长历史实验，我们保留最新的状态-动作对，同时使用TCN模型[12][14]对额外的历史进行编码，并将其潜在输出与策略输入连接起来。如图4所示，使用更长的历史（无论是短期还是长期）并不能比即时反馈（即最新的一步历史）提升性能。虽然与文献[14]有所不同，但本研究与L1自适应控制[21]和鲁棒控制方法[2]、[3]相一致，其中即时误差反馈至关重要。

表 IV：内部预测模型噪声容忍度评估，基于四旋翼跟踪之字形（zigzag）轨迹进行测试。

		噪声 on 训练	评估 静态	受到干扰 静态	受到干扰
		0.	0.057	0.064 (+12.28%)	0.101 0.119 (+17.82%)
输入 噪声	0.02	0.063	0.069 (+9.52%)	0.092	0.117 (+27.17%)
	0.04	0.070	0.094 (+34.28%)	0.100	0.154 (+54.00%)
	0.08	0.071	0.121 (+70.42%)	0.134	0.202 (+50.74%)
	0.16	0.082	0.135 (+64.63%)	0.152	0.231 (+51.97%)
输出 噪声	0.02	0.063	0.071 (+12.69%)	0.076	0.132 (+73.68%)
	0.04	0.073	0.097 (+32.87%)	0.102	0.161 (+57.84%)
	0.08	0.074	0.121 (+63.51%)	0.118	0.179 (+51.69%)
	0.16	0.076	0.130 (+71.05%)	0.138	0.222 (+60.86%)

该方法兼顾了精度和鲁棒性。这种更简单的结构也降低了实现的复杂性，并减少了实际机器人中的累积误差。2) 噪声容忍：为了评估内部预测模型精度对控制性能的影响，我们在模型的状态输入或预测中引入了不同程度的噪声。具体来说，我们向状态向量（包括位置、速度、四元数和角速度）引入了均值为零、方差不同的高斯噪声。对于四元数，我们将采样的高斯噪声视为欧拉角 δ ，将其转换为四元数 δ ，并应用于旋转原始方向。我们使用一系列带噪声的预测模型训练和评估了多种策略，用于四旋翼飞行器在之字形轨迹上的跟踪，结果如表IV所示。结果表明，无论应用于模型输入还是响应，我们的方法在轻微噪声下都能保持良好的性能。然而，随着噪声水平的增加，预测模型的准确性变得愈发关键，尤其是在存在外部干扰或系统动力学分布异常的情况下。在不同的训练和评估范围内，性能均随噪声的增强而下降，在外部力干扰下也观察到了类似的趋势。这一观察结果凸显了我们显式预测模型相对于其他基于学习的方法的优势：它提供了一个稳定的基线估计，尽管是近似的。虽然噪声建模可能会影响反馈的可靠性，但刚体变换遵循基本的运动原理，并且可以推广到各种机器人系统中。虽然该模型简化了




图 5：四旋翼飞行器搭载两种不同绳索悬挂载荷的实际实验。

表

V：内部预测模型复杂度的评估，测试对象为跟踪之字形轨迹的四旋翼飞行器。

模型训练评估静态扰动静态扰动				
Simplified	0.057	0.064 (+12.28%)	0.101	0.119 (+17.82%)
Full	0.061	0.067 (+9.84%)	0.095	0.105 (+10.53%)

针对非线性复杂性，我们框架中的强化学习（RL）部分在一个信息丰富的闭环系统中进行了有效补偿。3)

模型简化：我们研究了预测模型简化对性能的影响。由于四旋翼飞行器拥有研究透彻的动力学模型[40]，我们将其作为测试平台。我们将我们的方法与一种使用完整动力学模型跟踪“之”字形（zigzag）轨迹的变体进行了比较。如表 V

所示，结果表明，尽管进行了简化，性能下降却微乎其微。值得注意的是，这种简化提高了针对不同构型的泛化能力，使其适用于难以建模的复杂系统。

E. 实际部署

为了进一步验证我们框架的有效性，我们在四旋翼飞行器上进行了实际实验，部署了我们的方法以评估其在各种干扰下的鲁棒性。该四旋翼飞行器搭载了 Nvidia Jetson Xavier NX [42] 和 PX4 飞行控制单元 (FCU) [43]，并与运动捕捉系统交互以实现实时位姿跟踪。整个神经控制框架在嵌入式计算机上运行。控制策略生成 CTBR 指令，这些指令通过 MAVROS [44] 传输至 FCU 并转换为电机转速。该四旋翼飞行器重约 1 kg；我们在三种干扰条件下（无干扰、200g 载荷、330g 载荷）各进行了五次试验，以评估其跟踪性能，其中载荷均通过绳索悬挂以增加系统的不稳定性和非线性。部署系统的设置如图 5a 所示。我们在图 5b 中展示了各轴的跟踪性能以及所有轴的归一化误差。图中曲线表示不同条件下的平均跟踪误差，黑色区间表示方差。结果表明，该框架保持了相对稳定的

不同载荷下的性能。为了说明预测误差反馈的影响，我们提供了一个 330g

载荷的详细轨迹示例，作为实际场景中的消融研究（图 5c）。z

轴轨迹表明，如果没有预测误差反馈，由于意外的重型载荷，控制策略难以保持稳定的飞行高度。相比之下，我们的方法结合了预测误差反馈，即使受到额外有效载荷的向下作用力，也能实现稳健的跟踪。

V. 结论

本文提出了神经内模控制（NeuralIMC），这是一个连接基于模型的控制与基于强化学习（RL）的神经控制的框架。通过利用机体动力学和“白盒”刚体变换，我们避免了高维非线性问题，并在闭环反馈结构中采用了简化的预测模型。无模型强化学习使策略能够针对预测误差做出反应。NeuralIMC 在四旋翼飞行器和四足机器人上的表现优于现有的最先进控制器。针对重载四旋翼飞行器的实际测试证明了对扰动和动态变化的鲁棒性，凸显了其在可解释且自适应的基于学习的控制方面的潜力。在未来的工作中，我们计划开展更广泛的实际测试，包括在多种机器人上进行测试以及改进抗扰动训练 [45]。

参考文献

- [1] B. Pasik-Duncan, “Adaptive control [second edition, by Karl J. Åström and Björn Wittenmark, Addison Wesley (1995)],” IEEE Control Systems Magazine, vol. 16, no. 2, pp. 87–, 1996.
- [2] N. T. Nguyen and N. T. Nguyen, Model-reference adaptive control. Springer, 2018.
- [3] D. E. Rivera, M. Morari, and S. Skogestad, “Internal model control: PID controller design,” Industrial & engineering chemistry process design and development, vol. 25, no. 1, pp. 252–265, 1986.
- [4] K. J. Åström and B. Wittenmark, “On self tuning regulators,” Automatica, vol. 9, no. 2, pp. 185–199, 1973.
- [5] F. Lin, R. D. Brandt, and G. Saikalis, “Self-tuning of PID controllers by adaptive interaction,” in Proceedings of the 2000 American Control Conference. ACC (IEEE Cat. No. 00CH36334), vol. 5. IEEE, 2000, pp. 3676–3681.
- [6] B. A. Francis and W. M. Wonham, “The internal model principle of control theory,” Automatica, vol. 12, no. 5, pp. 457–465, 1976.
- [7] X. B. Peng, P. Abbeel, S. Levine, and M. van de Panne, “Deepmimic: Example-guided deep reinforcement learning of physics-based character skills,” ACM Trans. Graph., vol. 37, no. 4, pp. 143:1–143:14, Jul. 2018. [Online]. Available: <http://doi.acm.org/10.1145/3197517.3201311>

- [8] Y. Li, J. Li, W. Fu, and Y. Wu, "Learning agile bipedal motions on a quadrupedal robot," arXiv preprint arXiv:2311.05818, 2023. [9] E. Kaufmann, L. Bauersfeld, A. Loquercio, M. Müller, V. Koltun, and D. Scaramuzza, "Champion-level drone racing using deep reinforcement learning," *Nature*, vol. 620, no. 7976, pp. 982–987, 2023. [10] Y. Song, A. Romero, M. Müller, V. Koltun, and D. Scaramuzza, "Reaching the limit in autonomous racing: Optimal control versus reinforcement learning," *Science Robotics*, vol. 8, no. 82, p. eadg1462, 2023. [11] J. Hwangbo, J. Lee, A. Dosovitskiy, D. Bellicoso, V. Tsounis, V. Koltun, and M. Hutter, "Learning agile and dynamic motor skills for legged robots," *Science Robotics*, vol. 4, no. 26, p. eaau5872, 2019. [Online]. 可访问: <https://www.science.org/doi/abs/10.1126/scirobotics.aau5872> [12] A. Kumar, Z. Fu, D. Pathak, and J. Malik, "Rma: Rapid motor adaptation for legged robots," arXiv preprint arXiv:2107.04034, 2021. [13] J. Long, Z. Wang, Q. Li, L. Cao, J. Gao, and J. Pang, "Hybrid internal model: Learning agile legged locomotion with simulated robot response," 收录于第十二届国际学习表征会议 (ICLR), 2024. [14] Z. Li, X. B. Peng, P. Abbeel, S. Levine, G. Berseth, and K. Sreenath, "Reinforcement learning for versatile, dynamic, and robust bipedal locomotion control," arXiv 预印本 arXiv:2401.16889, 2024. [15] I. Radosavovic, T. Xiao, B. Zhang, T. Darrell, J. Malik, and K. Sreenath, "Real-world humanoid locomotion with reinforcement learning," *Science Robotics*, 卷 9, 期 89, p. eadi9579, 2024. [16] X. B. Peng, M. Andrychowicz, W. Zaremba, and P. Abbeel, "Sim-to-real transfer of robotic control with dynamics randomization," *IEEE 国际机器人与自动化会议 (ICRA)*, 2017. [17] N. Rudin, D. Hoeller, P. Reist, and M. Hutter, "Learning to walk in minutes using massively parallel deep reinforcement learning," 收录于第五届年度机器学习会议 (CoRL), 2021. [在线]. 可访问: <https://openreview.net/forum?id=wK2fDDJ5VcF> [18] M. O'Connell, G. Shi, X. Shi, K. Azizzadenesheli, A. Anandkumar, Y. Yue, and S.-J. Chung, "Neural-fly 实现强风中敏捷飞行的快速学习", 《科学·机器人学》(Science Robotics), 第 7 卷, 第 66 期, 页码 eabm6597, 2022 年. [19] Z. Li, J. Zeng, A. Thirugnanam and K. Sreenath, "通过低维线性模型的系统辨识, 连接基于模型的安全控制与无模型强化学习", arXiv 预印本 arXiv:2205.05787, 2022 年. [20] K. Huang, R. Rana, A. Spitzer, G. Shi 和 B. Boots, "DATT: 用于四旋翼控制的深度自适应轨迹跟踪", 载于第七届机器学习年度会议 (CoRL), 2023 年. [在线]. 可访问: <https://openreview.net/forum?id=XEw-cnNsr6> [21] F. L. Lewis, "L1 adaptive control theory: Guaranteed robustness with fast adaptation (hovakimyan, n. and cao, c.; 2010 [bookshelf])," *IEEE Control Systems Magazine*, vol. 31, no. 5, pp. 112–114, 2011. [22] S. Mallikarjunan, B. Nesbitt, E. Kharisov, E. Xargay, N. Hovakimyan, and C. Cao, "L1 adaptive controller for attitude control of multirotors," in *AIAA guidance, navigation, and control conference*, 2012, p. 4831. [23] J. Pravitra, K. A. Ackerman, C. Cao, N. Hovakimyan, and E. A. Theodorou, "L1-adaptive mppi architecture for robust and agile control of multirotors," in *2020 IEEE/RIS International Conference on Intelligent Robots and Systems (IROS)*. IEEE, 2020, pp. 7661–7666. [24] M. Mittal, C. Yu, Q. Yu, J. Liu, N. Rudin, D. Hoeller, J. L. Yuan, R. Singh, Y. Guo, H. Mazhar, A. Mandlekar, B. Babich, G. State, M. Hutter, and A. Garg, "Orbit: A unified simulation framework for interactive robot learning environments," *IEEE Robotics and Automation Letters*, vol. 8, no. 6, pp. 3740–3747, 2023. [25] B. Xu, F. Gao, C. Yu, R. Zhang, Y. Wu, and Y. Wang, "Omnidrones: An efficient and flexible platform for reinforcement learning in drone control," *IEEE Robotics and Automation Letters*, 2023. [26] D. Zhang, A. Loquercio, X. Wu, A. Kumar, J. Malik and M. W. Mueller, "针对差异巨大的四旋翼飞行器学习单一近悬停位置控制器", 载于 2023 年 IEEE 国际机器人与自动化会议 (ICRA). IEEE, 2023 年, 第 1263–1269 页. [27] J. Schulman, F. Wolski, P. Dhariwal, A. Radford and O. Klimov, "近端策略优化算法", arXiv 预印本 arXiv:1707.06347, 2017 年. [28] I. Koryakovskiy, M. Kudruss, H. Vallery, R. Babu'ska 和 W. Caarls, "利用强化学习补偿模型与实际系统之间的失配", 《IEEE 机器人与自动化快报》(IEEE Robotics and Automation Letters), 第 3 卷, 第 3 期, 第 2471–2477 页, 2018 年. [29] A. Kumar, Z. Li, J. Zeng, D. Pathak, K. Sreenath 和 J. Malik, "将快速电机适应技术应用于双足机器人", 载于 2022 年 IEEE/RIS 国际智能机器人与系统会议 (IROS). IEEE, 2022 年, 第 1161–1168 页. [30] M. A. Henson 和 D. E. Seborg, "一种针对非线性系统的内模控制策略", 《AIChE Journal》, 第 37 卷, 第 7 期, 第 1065–1081 页, 1991 年. [31] M. Bin. P. Bernard 和 L. Marconi, "基于辨识的自适应内模实现近似非线性调节", 《IEEE Transactions on Automatic Control》, 第 66 卷, 第 8 期, 第 3534–3549 页, 2020 年. [32] T. Qin. P. Li 和 S. Shen, "Vins-mono: 一种鲁棒且通用的单目视觉惯性状态估计器", 《IEEE Transactions on Robotics》, 第 34 卷, 第 4 期, 第 1004–1020 页, 2018 年. [33] L. Von Stumberg. V. Usenko 和 D. Cremers, "利用动态边缘化技术的直接稀疏视觉惯性里程计", 载于《2018 IEEE 机器人与自动化国际会议 (ICRA)》, IEEE, 2018 年, 第 2510–2517 页. [34] Intel RealSense, "视觉惯性追踪案例研究", 2024 年. [在线]. 网址: <https://www.intelrealsense.com/visual-inertial-tracking-case-study/> [35] Z. Teed. L. Lipson 和 J. Deng, "深度图块视觉里程计", 载于《神经信息处理系统进展 (NeurIPS)》, A. Oh, T. Naumann, A. Globerson, K. Saenko, M. Hardt, 和 S. Levine (编辑), 第 36 卷, Curran Associates, Inc., 2023 年, 第 39033–39051 页. [在线]. 可访问: https://proceedings.neurips.cc/paper_files/paper/2023/file/7ac484b0f1a1719ad5be9aa8c8455fbb-Paper-Conference.pdf [36] I. Newton, *Philosophiæ Naturalis Principia Mathematica*. London: Royal Society, 1687. [37] F. S. Grassia, "Practical parameterization of rotations using the exponential map," *Journal of graphics tools*, vol. 3, no. 3, pp. 29–48, 1998. [38] PX4, *Controller Diagrams — PX4 User Guide*, 2024. [Online]. Available: https://docs.px4.io/main/en/flight_stack/controller_diagrams.html [39] E. Kaufmann, L. Bauersfeld, and D. Scaramuzza, "A benchmark comparison of learned control policies for agile quadrotor flight," in *2022 International Conference on Robotics and Automation (ICRA)*. IEEE, 2022, pp. 10 504–10 510. [40] M. Faessler, D. Falanga, and D. Scaramuzza, "Thrust mixing, saturation, and body-rate control for accurate aggressive quadrotor flight," *IEEE Robotics and Automation Letters*, vol. 2, no. 2, pp. 476–482, 2016. [41] E. S'uli and D. F. Mayers, *An introduction to numerical analysis*. Cambridge university press, 2003. [42] NVIDIA Corporation, "Jetson xavier nx developer kit," <https://developer.nvidia.com/embedded/jetson-xavier-nx>. [43] L. Meier 等, "Px4: 一款专业级自动驾驶仪", <https://px4.io> 及 <https://github.com/PX4/PX4-Autopilot>, 2021 年. [44] MAVROS 贡献者, "Mavros: 面向 ROS 的 MAVLink 可扩展通信节点", <https://github.com/mavlink/mavros>. [45] J. Long, W. Yu, Q. Li, Z. Wang, D. Lin 和 J. Pang, "学习 H-infinity 运动控制", 载于第八届机器学习年会 (CoRL), 2024 年.