

针对无挂载及带挂载四旋翼飞行器的学习型增量非线性动态逆控制

Eckart Cobo-Briesewitz¹ COBO-BRIESEWITZ@CAMPUS.TU-BERLIN.DE Khaled Wahba¹ K.WAHBA@TU-BERLIN.DE Wolfgang Hönig^{1,2} HOENIG@TU-BERLIN.DE ¹柏林工业大学, 德国柏林 ²德国机器人研究所 (RIG)

摘要

多旋翼飞行器应用日益复杂,这就要求飞行控制器能够精确考量作用于飞行器的所有力。传统控制器虽然对大多数气动和动力学效应进行了建模,但往往忽略高阶力,因为精确估计这些力需要巨大的计算成本。增量非线性动态逆 (INDI) 提供了一种替代方案,通过传感器测量值的差异来估计残余力;然而,它对专用且往往伴随噪声的传感器的依赖限制了其适用性。近期研究表明,利用基于学习的方法可以预测残余力。本文展示了神经网络无需专用旋翼转速 (RPM) 传感器输入,即可生成 INDI 输出的平滑近似值。此外,我们提出了一种将基于学习的预测与 INDI

相结合的混合方法,并针对普通多旋翼飞行器及携带挂载的多旋翼飞行器验证了这两种方法。

关于轨迹跟踪误差的实验结果表明,通过用神经网络替代残余力计算,可以省去 INDI 所需的专用传感器测量。关键词: 基于学习的控制,残余力估计,四旋翼飞行器,挂载。

1. 引言

多旋翼飞行器执行任务的复杂性不断增加,这促使人们开发更精确的飞行控制器,以便对作用于这些机器人的所有力进行建模。传统的飞行控制器 (Lee 等人, 2010) 虽然能对其中大部分力进行建模,但无法涵盖所有力。剩余的力 (称为“残余力”) 可能源于多种因素,例如旋翼挥舞、阻力或地面效应力 (Shi 等人, 2020, 2022; Bauersfeld 等人, 2021)。直接计算残余力在计算上可能非常复杂,难以满足实时控制的需求,尤其是在硬件资源受限的四旋翼飞行器上。近期研究表明,学习算法能显著提升飞行性能 (Bauersfeld 等人, 2021), 甚至能对多个四旋翼飞行器之间的相互作用力进行建模 (Shi 等人, 2020)。通过仅学习残余力而非四旋翼的完整动力学特性,所需的训练数据量得以大幅减少。此外,当传感器读数存在噪声或数据缺失时,学习模型也有助于改善飞行性能。增量非线性动态逆 (INDI) 方法 (Smeur 等人, 2016) 利用标称动力学模型与实时传感器反馈之间的偏差来推导残余力,并利用该残余力对控制输入进行增量式修正。在无人机 (UAV) 应用中,INDI 通常依赖旋翼转速 (RPM) 测量值来近似标称模型。尽管 INDI 能显著增强飞行性能,但其有效性取决于特定传感器数据的可用性,且仍可能受到测量噪声的影响。

多旋翼飞行器的一个极具前景的应用领域是载荷运输，特别是在医疗和救援行动等对时间敏感的场景中。当机器人通过缆索悬挂载荷进行运输时（Tang 等人，2014；Wahba 和 Hönig，2023），由于载荷的引入会对系统施加额外的力，多旋翼飞行器的动力学特性会变得更加复杂。这些新增的动力学特性可能引发新型未建模残余力，从而增加了对高精度估计器的需求，并使残余力预测变得愈发关键。




图1：本文比较的三种计算残余力方法的概览：a)

标准INDI依赖额外的传感器测量，这些测量可能成本高昂且易受噪声影响。b)

学习型INDI（LINDI）学习INDI的输出，无需专用传感器，并能产生更平滑的预测结果。c)

神经增强型INDI（NA-INDI）将LINDI的预测与原始传感器数据融合，从而获得更高质量的残余力估计。LINDI和NA-INDI在第4节中进行了正式定义。

我们提出了一种基于神经网络的方法——学习型增量非线性动态逆（LINDI），该方法无需测量旋翼转速（RPM）即可实现与INDI控制器相当的飞行性能。通过用一个学习型组件替代增量模型，并将其集成到两种传统的飞行控制器（Lee等人，2010；Yu等人，2020）中，我们的方法消除了对专用RPM传感器的需求。定量结果表明，该方法在性能上与INDI相当；此外，我们还分析了一种结合了INDI和神经网络预测的混合架构——神经增强型增量非线性动态逆（NA-INDI）。图1总结了这三种评估过的方法。



图2：实验所用的硬件。我们使用的是配备标准电机、Micro-SD卡扩展模块以及基于红外LED（IR-LED）的定制RPM测量板的Bitcraze Crazyflie 2.1无人机。这些LED也可由运动捕捉系统进行追踪。有效载荷上还装有另一个用于追踪的主动式红外LED。

2. 相关工作

多项既往研究强调了INDI对于实现高追踪性能（特别是在高速飞行中）的重要性。具体而言，对于基于模型预测控制（MPC）和基于几何方法的控制器，引入INDI组件都至关重要；当给定有效的参考轨迹时，这两种方法均能实现相当的性能（Sun等人，2022）。通过对阻力（Sun et al., 2022; Faessler et al., 2018）或电机延迟（Tal and Karaman, 2021）进行建模，可以进一步提升性能，尽管这些因素的影响相对较小。近期研究还表明，INDI在携带载荷的多旋翼飞行器敏捷飞行中发挥着关键作用（Sun et al., 2025）。

除了INDI中采用的在线估计方法外，另一种方案是学习一个能够直接预测非线性残余动力学的函数。Bauersfeld等人（2021）提出通过引入神经网络来增强控制器，该网络用于预测作用于四旋翼飞行器上的残余力。他们的方法采用了非马尔可夫假设，即利用历史状态而非仅当前状态作为输入。该网络输出一个六维向量，表示沿 x 、 y 和 z 轴的残余力和力矩。实验结果表明，此类学习得到的残余模型能显著提升飞行性能。同样，Shi等人（2022）研究了由四旋翼飞行器间相互作用（特别是下洗流效应，即上方的四旋翼对下方的四旋翼产生向下的作用力）引起的残余力。他们的方法利用 DeepSets 架构聚合针对每个四旋翼的独立神经网络输出，从而实现沿 z 轴残余力的预测。该方法将下洗流工况下的最差 z 轴位置误差降低了 2 到 4 倍。

近期的研究探索了将INDI框架与基于学习的模型相结合。Ignatyev和Tsourdos（2022）采用高斯过程实时校正传感器测量误差，并在线更新该高斯过程。相比之下，Zhang和Ran（2023）利用元学习在飞行过程中持续调整残余预测，通过更新神经网络来估计INDI控制效能矩阵。我们的方法与以往工作的不同之处在于：模型采用离线训练并直接预测INDI输出，从而避免了在线模型未完全收敛时可能出现的不稳定性，同时也无需特殊的传感器测量。此外，与以往研究不同，我们通过针对两种不同四旋翼机型的大规模实际飞行测试，验证了该方法的有效性。

此前已有研究将基于学习的方法应用于多旋翼飞行器的悬挂式载荷运输。例如，Jin等人（2024）采用神经网络来预测未知载荷对多旋翼飞行器产生的作用力。相比之下，我们的研究假设载荷已知，并专注于残余动力学特性。

与以往研究相比，我们方法的主要贡献在于：它无需测量旋翼转速（RPM），同时在实验中展现出可与INDI媲美的飞行性能，且残余力预测更为平滑、噪声更低。

3. 问题描述

我们首先介绍本研究中考虑的动力学模型，随后阐述我们要解决的控制问题。

3.1. 多旋翼动力学

考虑一个建模为刚性浮动基座的多旋翼飞行器，其状态表示为 $x = [p, R, v, \omega]$ 。其中， $p, v \in \mathbb{R}^3$ 分别表示世界坐标系下的位置和速度， $R \in \text{SO}(3)$ 表示从机体坐标系到世界坐标系的旋转矩阵， $\omega \in \mathbb{R}^3$ 表示机体坐标系下的角速度。控制输入 $u \in \mathbb{R}$ 定义为各旋翼的角速度，即 $u = [r_1, r_2, r_3, r_4]$ 。其动力学方程由刚体的牛顿-欧拉方程导出，形式如下：

$$\dot{p} = v, \quad m\dot{v} = f_u R e_z - m g e_z + f_a, \quad (1)$$

$$\dot{R} = R \hat{\omega}, \quad J \dot{\omega} = J \omega \times \omega + \tau_u + \tau_a, \quad (2)$$

其中 m 为质量， J 为惯性矩阵， g 为重力加速度常数， $e_z = [0, 0, 1]$ ， f_u 为旋翼产生的总推力， τ_u 为旋翼产生的力矩向量， f_a 和 τ_a 分别为未知的外部力和力矩， ω 表示 ω 对应的反对称矩阵，使得对于任意向量 v 均有 $\omega v = \omega \times v$ 。电机角速度与作用于刚体上的总力及力矩之间的关系为：

$$f_i = \kappa F r_2^i, \quad (3a)$$

$$[f_u, \tau_u]^T = B_0 [f_1, f_2, f_3, f_4]^T, \quad (3b)$$

其中 κF 为螺旋桨常数， B_0 为固定且已知的驱动矩阵。

3.2. 悬挂载荷的多旋翼飞行器

考虑一个连接在多旋翼飞行器质心处的悬挂式载荷。多旋翼飞行器的状态量进行了扩展，纳入了载荷的位置 p_p 和速度 v_p 。平移动力学方程也增加了相应的项：

$$m \dot{v} = f_u R e_z - m g e_z + T q + f_a, \quad (4)$$

$$\dot{p}_p = v_p, \quad m_p \dot{v}_p = -T q - m_p g e_z \quad (5)$$

其中 $q = p_p - p$ ， $\|p_p - p\|$ 表示缆索的方向， m_p 为载荷质量， T 为缆索张力。根据式 (4)，张力可计算为：

$$T = m_p q (\dot{v}_p + g e_z). \quad (6)$$

3.3. 控制问题

给定标称模型和可行的参考轨迹 $x_r(t)$ ，我们的目标是寻找能够最小化平均跟踪误差的控制器：

$$\arg \min_{\pi} \frac{1}{D} \int_0^D d(x_\pi(t), x_r(t)) dt, \quad (7)$$

其中 $\pi(x, x_r) \mapsto u$ 是影响状态 $x_\pi(t)$ 的控制律， D 是参考轨迹 $x_r(t)$ 的持续时间， d 是距离度量。对于多旋翼情况，我们考虑位置跟踪误差，即 $d(x_\pi, x_r) = \|p_\pi - p_r\|_2$ ；对于载荷运输情况，则考虑载荷的位置跟踪误差。在本研究中，我们利用测量和/或预测分量来增强那些忽略了 f_a 和 τ_a 的经典控制器，从而改善跟踪性能 (7)。

4. 方法

本节介绍我们提出的两种方法。学习型增量非线性动态逆 (LINDI) 是一种基于学习的方法，它无需 INDI 所需的额外传感器测量，同时通过从平滑数据中学习来保持甚至提升性能。神经增强型增量非线性动态逆 (NA-INDI) 结合了神经网络的输出与 INDI 传感器测量值，从而实现优于 INDI 和 LINDI 的性能。

4.1. 几何控制律

4.1.1. 多旋翼飞行器

针对多旋翼飞行器的指数稳定几何控制器按如下方式计算期望力和力矩 (Lee 等人, 2010 年)：

$$f_u = (K_p e_p + K_v e_v + m g e_z + m \ddot{p}_d + \dot{f}_a) \cdot \text{Rez}, \quad (8a)$$

$$\tau_u = K_R e_R + K_\omega e_\omega + J \dot{\omega} \times \omega - J(\dot{\omega} R^\top R_d \omega_d - R^\top R_d \dot{\omega}_d) - \tau_a, \quad (8b)$$

其中 R_d 、 ω_d 和 $\dot{\omega}_d$ 是可通过微分平坦性 (differential flatness) 计算得出的期望参考量； e_p 、 e_v 、 e_R 、 $e_\omega \in \mathbb{R}^3$ 是相对于该参考量的误差 (数学定义见 Lee 等人 (2010) 的文献)； K_p 、 K_v 、 K_R 、 $K_\omega \in \mathbb{R}^{3 \times 3}$ 是对角正定增益矩阵。高亮显示的项 f_a 和 τ_a 是需要添加的新项，用于补偿残余力和力矩。

4.1.2. 带有缆索悬挂载荷的多旋翼飞行器

上述控制律可扩展用于跟踪缆索悬挂载荷 (Yu 等人, 2020)。该控制器采用级联设计：第一级跟踪载荷的位置和速度，第二级跟踪期望的缆索方向及其导数，第三级跟踪无人机的旋转和角速度。最终， f_u 计算出多旋翼飞行器为跟踪期望的缆索和载荷运动而产生的控制力，同时抑制外部残余力 f_a 。

$$f_u = (u_0 - f_a) \cdot \text{Rez}, \quad (9)$$

其中 u_0 是 Yu 等人 (2020) 定义的用于跟踪缆索的名义控制力。最后，旋转动力学方程与 (8b) 相同，因为假设缆索连接在重心处，且名义模型与实际模型之间的偏差通过 τ_a 进行补偿。

4.2. 增量非线性动态逆 (INDI)

增量非线性动态逆 (INDI) 的核心思想是利用惯性测量单元 (IMU) 和转速 (RPM) 传感器的测量值实时估计 f_a 和 τ_a 。INDI 控制器应用于 Smeur 等人 (2016) 及 Tal 和 Karaman (2021) 文献中所述的多旋翼飞行器动力学模型。多旋翼-负载系统的动力学特性与标准情况不同，主要区别在于缆索施加的力。因此，对式 (2) 和 (4) 进行重写，可得：

$$f_a = m \ddot{v} - f_u \text{Rez} + m g e_z - T_q, \quad (10a)$$

$$\tau_a = J \dot{\omega} - J \omega \times \omega - \tau_u. \quad (10b)$$

在 INDI 方法中, f_u 和 τ_u 是通过应用式 (3) 并利用转速 (RPM) 测量值计算得出的; $\dot{v}$ 由机体坐标系下的加速度计测量并转换至世界坐标系; ω 则由陀螺仪测量。其他变量 (如式 (6) 中所需的 $\dot{\omega}$ 和 $\dot{v}_p$) 通过数值方法估算, 而 R 和 q 则由状态估计过程计算得出。在实际应用中, 对测量值进行滤波 (例如使用巴特沃斯滤波器, Tahir 和 Karaman, 2021) 至关重要。在线估算值可用作控制器中的附加前馈项, 如式 (8) 和 (9) 所示。在 INDI 框架内, 多旋翼-负载系统的动力学建模既可以显式包含负载和缆索的动力学特性 (Sreenath 等人, 2013; Yu 等人, 2020; Li 等人, 2023), 也可以通过缆索张力来表征两者间的耦合关系 (Sun 等人, 2025; Sreenath 和 Kumar, 2013)。鉴于其实用性, 我们在式 (4) 中采用了后者。关于显式包含缆索动力学的完整公式及其选择依据, 请参阅附录。

4.3. 学习型增量非线性动态逆 (LINDI)

利用包含 IMU 数据、转速 (RPM) 数据和状态估计值的轨迹样本数据集, 可以通过公式 (10) 计算出 f_a 和 τ_a 。在此过程中, 可利用样条拟合等零延迟滤波器对 $\dot{v}$ 和 $\dot{\omega}$ 等含噪数据进行预处理。由此得到的 f_a 和 τ_a 数值即为监督学习任务中的标签。针对单四旋翼飞行器的情况, 我们采用多层感知机 (MLP) 模型, 该模型包含 19 个输入、6 个输出以及两个维度均为 24 的隐藏层, 并使用 Leaky-ReLU 激活函数。输入变量包括 v 、 $\dot{v}$ 、 ω 、旋转矩阵 R 的前两列以及电机 PWM 信号 (该信号不同于 r_i , 因为它无法反映电机延迟)。输出为残余力和力矩 $[f_a, \tau_a]^T \in \mathbb{R}^6$ 。网络输入和输出均采用最小-最大归一化 (min-max normalization) 缩放至 $[-1, 1]$ 区间, 以减小数值量级差异并提高训练稳定性。对于载荷网络, 输入维度扩展至 28, 增加了载荷速度、加速度及缆索方向等变量; 纳入这些变量是因为它们提供了估算作用于载荷的残余力所需的相关信息。网络架构保持不变, 仅将隐藏层维度减小为 16; 这是因为在载荷场景下残余力特征更为显著, 训练过程相对容易, 从而允许使用较小的网络规模。在预处理阶段, 我们拟合由三次多项式段构成的样条曲线, 旨在最小化相对于数据点的 L2 误差, 而非进行精确插值。将这些样条曲线应用于采集到的 INDI 输出信号, 所得平滑信号即作为训练标签。图 3 展示了基于平滑数据进行训练的效果。由于该平滑处理是在离线状态下进行的, 其效果优于 INDI 在线控制中使用的巴特沃斯 (Butterworth) 滤波器。

4.4. 神经增强增量非线性动态逆 (NA-INDI)

我们将未建模动力学项拆分为两部分: $f_a = f_{a,\text{NN}} + f_{a,\text{INDI}}$ (τ_a 同理), 其中 $f_{a,\text{NN}}$ 和 $\tau_{a,\text{NN}}$ 是利用 4.3 节所述步骤训练得到的学习函数。随后, INDI 控制律仅需针对动力学中剩余的偏差进行补偿。

5. 实验

为了量化不同方法的性能, 我们在两条未曾用于神经网络训练的飞行轨迹上进行了实际飞行测试。





图 3：该图展示了针对 y 轴残余加速度的两个不同 MLP（多层感知机）的输出，并与原始 INDI 预测值进行了对比；测试场景为携带载荷的四旋翼飞行器沿“8”字形（Figure-8）轨迹飞行。左图展示了基于原始 INDI 输出训练的 MLP 的预测结果，右图则展示了基于样条拟合后的 INDI 输出训练的 MLP 的结果。尽管标准 MLP 具有一定的固有去噪能力，但在使用噪声较小的数据（尤其是使用较小规模数据集）进行训练时，其产生的预测结果明显更为平滑。



(a) 随机点 (b) “8”字形轨迹 (c) 圆形轨迹

图 4：图 (a) 展示了用于生成神经网络训练数据的示例轨迹。通过在预定义的边界框内采样随机点来构建样条轨迹，四旋翼飞行器以最高 2 m/s 的速度沿该轨迹飞行。图 (b) 和 (c) 展示了用于测试不同控制器性能的轨迹。

5.1. 物理实验设置

我们在实验中使用 Bitcraze Crazyflie 2.1 四旋翼飞行器，这是一款臂长 4.6 厘米、重 34.7 克的微型四旋翼飞行器。它由 STM32 微处理器（168 MHz，1 MB 闪存，192 KB RAM）控制。我们在标准机器人上加装了两个组件：一个用于将数据记录到 microSD 卡¹ 的市售 PCB，以及一个用于测量转速（RPM）的定制 PCB（如图 2 所示）。为了精确预测四旋翼飞行器的位置，我们在 7.5 米 × 4 米 × 2.75 米的飞行空间内使用了运行频率为 100 Hz 的 OptiTrack 动作捕捉系统。用于测量转速的定制 PCB 采用红外发射器/接收器，并可作为 OptiTrack 动作捕捉系统的有源标记点，用于估计机器人的位姿。旋翼叶片下方装有反射标记，使红外接收器能够计数旋翼的转动次数。我们使用 Crazyswarm2 与四旋翼飞行器进行通信；该系统基于 Crazyswarm (Preiss et al., 2017) 开发，但采用了 ROS 2 (Macenski et al., 2022) 架构。

1. <https://www.bitcraze.io/products/micro-sd-card-deck/>

在载荷实验场景中，我们使用一根 0.5 米长的细绳将一个 5 克的重物悬挂在四旋翼飞行器的中心。细绳通过磁铁与四旋翼飞行器连接。如图 2 所示，载荷上也配备了红外 LED，用于估计其位置。为简化起见，我们保持载荷的尺寸和质量不变；关于适应不同载荷参数的相关研究，请参阅 Jin 等人 (2024) 的工作。

5.2. 数据采集 与训练

我们利用一组轨迹对神经网络进行训练，这些轨迹是通过在尺寸为 $1.6 \times 1.6 \times 0.4 \text{ m}^3$ 的预定义边界框内采样随机点生成的。这些点用于定义样条轨迹，四旋翼飞行器将沿该轨迹飞行；飞行速度为随机采样值，无负载情况下最高可达 2 m/s，有负载情况下最高可达 1.75 m/s。针对无负载场景，我们共采集了 64,996 个时间戳（约 12 分钟的飞行数据），每个数据点包含状态与残余力及力矩的组合；针对有负载场景，则采集了 58,538 个时间戳。我们使用 ADAM 优化器（Kingma 和 Ba, 2015），采用 L1 损失函数和 3×10^{-1} 的初始学习率；为增强训练的稳定性与收敛性，每 10 个 epoch 将学习率乘以 0.92 进行衰减；总训练轮数为 128 个 epoch，批次大小（batch size）为 512。针对单架无人机和携带负载无人机的网络，我们采用相同的训练流程，但使用各自场景对应的数据集。在离线测试中，我们发现不同超参数设置下的性能表现相似，因此省略了详细的消融研究。我们的目标是展示基于学习的模型能够替代专用传感器测量，而非优化某种特定架构。所有神经网络均在四旋翼飞行器的硬件上本地运行。对于 4.3 节所述的 MLP，其在 Crazyflie 硬件上的推理时间为 203 微秒。

5.3. 测试场景

我们在两条未包含在训练集中的预定义轨迹上测试控制器的性能。这些轨迹如图 4 所示。我们计算每次试验的平均跟踪误差（公式 7），并进行多次试验（具体见图注）。我们在有负载和无负载两种场景下进行相同的实验，唯一的区别在于飞行速度。在无负载工况下，最大速度为 2 m/s；而在有负载工况下，最大速度约为 1.75 m/s。

5.4. 结果


我们将所提方法与标准 INDI 控制器及不包含残余力预测的几何控制器（Lee 等人，2010）进行了对比。

5.4.1. RPM 测量对于 INDI 的重要性

为了验证 INDI 对 RPM（转速）测量的依赖性，我们测试了一种改进版 INDI 的性能，该版本使用脉宽调制（PWM）值而非 RPM 来测量旋翼的总推力输出。在此实验中，我们基于 INDI-PWM 的预测结果训练了 LINDI 和 NA-INDI，结果如表 1 所示。PWM 测量值存在噪声，并在推力估计中引入了由延迟引起的不匹配。

表 1：无载荷四旋翼飞行器在基于 PWM 信号推力（而非 RPM）的 INDI 控制下，偏离期望飞行路径的平均偏差（单位：厘米）对比。各方法的性能数据取自十次试验的平均值。

	Circle	Figure8
Lee	7.52 ± 1.22	7.29 ± 0.31
INDI-PWM	18.27 ± 0.97	18.89 ± 1.82
LINDI-PWM	15.33 ± 1.90	14.53 ± 1.75
NA-INDI-PWM	14.31 ± 1.91	16.71 ± 2.80




(a) “8”字形轨迹 (b) 圆形轨迹

图 5：无载荷四旋翼飞行器在 (a) “8”字形飞行轨迹和 (b) 圆形轨迹下，四种方法的性能对比。每个小提琴图包含 20 个数据点，代表每次试验中多旋翼位置 (7) 的平均跟踪误差（单位：厘米）。“8”字形轨迹的平均值：Lee: 7.07, INDI: 4.28, LINDI: 4.41, NA-INDI: 4.14。圆形轨迹的平均值：Lee: 7.45, INDI: 4.33, LINDI: 4.87, NA-INDI: 4.26。

结果表明，与基于 PWM 的 INDI 相比，利用 LINDI 和 NA-INDI 学习基于 PWM 的 INDI 的残余力计算，能显著提升飞行性能；但与不含残余力预测的基础 Lee 控制器相比，其性能仍显不足。这凸显了 INDI 对精确传感器测量的依赖性。此外，我们还发现，训练这些学习方法仍需依赖 RPM 测量数据。LINDI-PWM 和 NA-INDI-PWM 相比 INDI-PWM 的改进表明，LINDI 的去噪能力有望提升标准 INDI 的性能。

5.4.2. 无负载多旋翼飞行器

图 5 显示，残差预测能将针对期望飞行轨迹的跟踪误差降低约 40%。结果表明，LINDI 在不使用 RPM 测量值的情况下，实现了与 INDI 相当的性能；但在圆形轨迹上，性能略有下降，这可能是由于该轨迹相对于训练数据而言属于“分布外”（out-of-distribution）数据。结果还显示，结合传感器测量值与学习到的残差（即 NA-INDI）能获得最佳性能，尽管优势幅度较小。这是因为 RPM 测量值中的噪声更容易滤除：INDI 组件只需处理较小部分的残差，而其余效应则由 LINDI 组件处理。



(a) “8”字形轨迹 (b) 圆形轨迹

图 6：携带负载的四旋翼飞行器在 (a) “8”字形轨迹和 (b) 圆形轨迹下，四种方法的性能对比。每个小提琴图包含十个数据点，代表每次试验中负载位置 (7) 的平均跟踪误差（单位：厘米）。“8”字形轨迹的平均值：Lee: 7.06, INDI: 5.38, LINDI: 5.46, NA-INDI: 5.39。圆形轨迹的平均值：Lee: 7.26, INDI: 5.91, LINDI: 5.78, NA-INDI: 5.74。

5.4.3. 携带载荷的多旋翼飞行器

图6展示了与单架四旋翼飞行器实验类似的结果。结果再次表明，即便面对载荷带来的更复杂动力学特性，LINDI 依然能够在无需转速（RPM）测量的情况下，达到与 INDI 相当的性能水平。NA-INDI 显示出超越 INDI 的潜力，但目前的实际性能表现与之相当。

6. 结论

我们提出了 LINDI，这是一种学习残差预测的新颖方法，它基于样条拟合在平滑数据上训练神经网络。结果表明，神经网络可以有效替代 INDI，在无需特殊传感器测量的情况下输出更平滑的残差力预测。尽管该方法需要配备转速（RPM）测量传感器的四旋翼飞行器来采集训练数据，但一旦神经网络训练完成，即可部署到任意数量规格相似的四旋翼飞行器上。这能显著降低维护配备高精度飞行控制器的庞大无人机机队的成本。这项作为将基于学习的残差建模扩展到涉及外部气动干扰的更真实场景奠定了基础。探索 LINDI 在此类外部影响下的表现，为未来研究开辟了有前景的途径，并有望实现面向实际操作的、鲁棒且具备干扰感知能力的残差预测。

致谢

本项工作得到了德国研究联合会（DFG）的资助（项目编号：448549715）。

参考文献

L. Bauersfeld, E. Kaufmann, P. Foehn, S. Sun, and D. Scaramuzza. Neurobem: Hybrid aerodynamic quadrotor model. In Robotics: Science and Systems XVII. Robotics: Science and Systems

Foundation, 2021.

Matthias Faessler, Antonio Franchi, and Davide Scaramuzza. Differential flatness of quadrotor dynamics subject to rotor drag for accurate tracking of high-speed trajectories. *IEEE Robotics and Automation Letters*, 3(2):620–626, 2018. doi: 10.1109/LRA.2017.2776353.

Dmitry Ignatyev and Antonios

Tsourdos. 针对部分未知系统的增量非线性动态逆与稀疏在线高斯过程自适应方法。载于《地中海控制与自动化会议 (MED)》论文集, 第233–238页, 2022年。doi: 10.1109/MED54222.2022.9837175。

Ao Jin, Chenhao Li, Qinyi Wang, Ya Liu, Panfeng Huang, 和 Fan Zhang. 用于带载荷飞行控制的神经预测器。arXiv 预印本 arXiv:2410.15946, 2024年。网址: <https://arxiv.org/abs/2410.15946>。

D. P. Kingma 和 J. Ba. Adam: 一种随机优化方法。载于《第三届国际学习表征会议 (ICLR)》论文集, 2015年。

T. Lee, M. Leok, 和 N. H. McClamroch. SE(3) 空间上四旋翼无人机的几何跟踪控制。载于《IEEE 决策与控制会议 (CDC)》论文集, 2010年。

Guanrui Li, Xinyang Liu, 和 Giuseppe Loianno. RotorTM: 一种用于空中运输与操作的灵活仿真器。《IEEE 机器人学汇刊 (IEEE Transactions on Robotics)》, 40:831–850, 2023年。

S. Macenski, T. Foote, B. Gerkey, C. Lalancette, 和 W. Woodall. 机器人操作系统 2 (ROS 2): 设计、架构及实际应用。《科学机器人 (Science Robotics)》, 7(66), 2022年。

J. A. Preiss, W. Hönig, G. S. Sukhatme, 和 N.

Ayanian. CrazySwarm: 一种大规模纳米四旋翼无人机群。载于《IEEE 机器人与自动化国际会议 (ICRA) 论文集》, 第 3299–3304 页, 2017 年。

Guanya Shi, Wolfgang Hönig, Yisong Yue, 和 Soon-Jo

Chung. Neural-swarm: 利用学习到的交互机制实现多旋翼飞行器的去中心化近距离控制。载于《IEEE 机器人与自动化国际会议 (ICRA)》, 2020 年。

Guanya Shi, Wolfgang Hönig, Xichen Shi, Yisong Yue, 和 Soon-Jo

Chung. Neural-swarm2: 利用学习到的交互机制实现异构多旋翼飞行器集群的规划与控制。《IEEE 机器人汇刊 (IEEE Transactions on Robotics)》, 38(2):1063–1079, 2022 年。doi: 10.1109/TRO.2021.3098436。

Ewoud J. J. Smeur, Qiping Chu, 和 Guido C. H. E.

Croon. 微型飞行器姿态控制的自适应增量非线性动态逆方法。《美国航空航天学会 (AIAA)》, 39(3):450–461, 2016 年。doi: 10.2514/1.G001490。

Koushil Sreenath 和 Vijay R.

Kumar. 多四旋翼机器人通过缆索悬挂载荷进行协同操纵的动力学、控制与规划。载于《机器人: 科学与系统 (Robotics: Science and Systems)》, 2013 年。

Koushil Sreenath, Taeyoung Lee, 和 Vijay

Kumar. 悬挂负载四旋翼无人机的几何控制与微分平坦性。载于 IEEE 决策与控制会议 (IEEE Conference on Decision and Control) , 第 2269–2274 页, 2013 年。

Sihao Sun, Angel Romero, Philipp Foehn, Elia Kaufmann, 和 Davide Scaramuzza。四旋翼飞行器敏捷飞行中非线性模型预测控制 (NMPC) 与基于微分平坦性控制的对比研究。《IEEE 机器人学汇刊》(T-RO), 2022 年。预印本可在 https://rpg.ifi.uzh.ch/docs/TRO22_Sun.pdf 获取。

Sihao Sun, Xuerui Wang, Dario Sanalitra, Antonio Franchi, Marco Tognon, 和 Javier Alonso-Mora。悬挂负载的敏捷协同空中操作。《科学·机器人学》(Science Robotics), 10(107):eadu8015, 2025 年。

Ezra Tal 和 Sertac Karaman。利用增量非线性动态逆与微分平坦性实现四旋翼激进轨迹的精确跟踪。《IEEE 控制系统技术汇刊》(IEEE Transactions on Control Systems Technology), 29(3):1203–1218, 2021 年。doi: 10.1109/TCST.2020.3001117。

Sarah Tang, Koushil Sreenath, 和 Vijay Kumar。悬挂载荷四旋翼飞行器的激进机动。载于《机器人学：科学与系统》(Robotics: Science and Systems) 会议, “机器人领域的女性”研讨会 (Workshop on Women in Robotics), 第 1–20 页, 2014 年。

Khaled Wahba 和 Wolfgang Hönig。针对多旋翼编队吊运载荷几何控制的高效优化缆索张力分配方法。载于《2023年IEEE国际机器人与自动化会议 (ICRA)》论文集, 第1234–1240页, 2023年。doi: 10.1109/ICRA48506.2023.1234567。

Beomyeol Yu, Kanishke Gamagedara, Seungkeun Kim, Taeyoung Lee, 和 Jinyoung Suk。四旋翼无人机吊运载荷的几何控制与实验验证。载于《IEEE决策与控制会议 (CDC)》论文集, 第201–207页, 2020年。

Xinyue Zhang 和 Maopeng Ran。基于元学习的四旋翼抗扰增量非线性动态逆控制。《应用科学》(Applied Sciences), 13(21):11844, 2023年。doi: 10.3390/app132111844。特刊：智能无人系统技术与应用。

附录 A. 缆索悬挂载荷动力学

单架四旋翼通过缆索（建模为刚性杆）吊运质点载荷的动力学行为由以下方程描述。参考 Tang 等人 (2014)；Sreenath 等人 (2013)；Yu 等人 (2020)；Li 等人..... (2023)，基于哈密顿原理，四旋翼与负载的耦合动力学可表示为

$$\begin{aligned} m_T \ddot{\mathbf{p}} &= \mathbf{u} - m_l \|\boldsymbol{\Omega}\|^2 \mathbf{q} - m_T \mathbf{g}_{ez} + \mathbf{f}_{ap}, \\ \dot{\mathbf{q}} &= \boldsymbol{\Omega} \times \mathbf{q}, \\ \dot{\boldsymbol{\Omega}} &= -m_l^{-1} \mathbf{q}_1 \mathbf{u}_\perp + \mathbf{f}_{ac}, \\ \dot{\mathbf{R}} &= \mathbf{R} \hat{\boldsymbol{\omega}}, \\ \mathbf{J} \dot{\boldsymbol{\omega}} &= \mathbf{J} \boldsymbol{\omega} \times \boldsymbol{\omega} + \boldsymbol{\tau}_u + \boldsymbol{\tau}_a, \end{aligned} \quad (11)$$

其中 $m_T = m_p + m$ 为负载-四旋翼系统的总质量。向量 $\mathbf{p}$ 、 $\mathbf{v}$ 、 $\mathbf{a} \in \mathbb{R}^3$ 分别表示负载的位置、速度和加速度。单位向量 $\mathbf{q}$ 指向从四旋翼位置 $\mathbf{x} \in \mathbb{R}^3$ 到负载位置 $\mathbf{x}_p$ 的方向， $\boldsymbol{\Omega} \in \mathbb{R}^3$ 表示缆索的角速度。四旋翼施加的总控制力分解如下

$$\mathbf{u}_0 = \mathbf{u}^\parallel + \mathbf{u}^\perp, \quad (12)$$

其中平行分量和垂直分量定义为

$$\mathbf{u}^\parallel = q q^\top \mathbf{f}_u \mathbf{e}_z, \mathbf{u}^\perp = -q q^\top \mathbf{f}_u \mathbf{e}_z, \quad (13)$$

$\mathbf{f}_u$ 为四旋翼产生的总推力。作用于系统的剩余气动力分别由 $\mathbf{f}_{ap}$ 和 $\mathbf{f}_{ac}$ 表示，分别作用于负载和缆索动力学。(11) 式中的最后两个方程描述了四旋翼的旋转动力学。

附录 B. 缆索悬挂负载的几何 INDI 控制器

本节展示了 Yu 等人 (2020) 提出的替代几何控制器以及显式包含缆索动力学的 INDI 形式（本文贡献）的完整数学推导。其目的是为正文中使用的 INDI 变体提供理论基础。我们采用一种几何 INDI 形式，其中载荷跟踪由沿缆索方向的虚拟力控制器 $\mathbf{F}_d$ 调节，而缆索姿态则由垂直分量控制。我们考虑载荷的一条平滑参考轨迹，该轨迹由其期望位置、速度、加速度以及最高至 n 阶的高阶导数（ $\mathbf{p}_{pd}, \mathbf{v}_{pd}, \mathbf{a}_{pd}, \mathbf{j}_{pd}, \mathbf{x}^{(n)}_{pd}$ ）定义。令 $\mathbf{e}_p = \mathbf{p}_{pd} - \mathbf{p}_p$ ， $\mathbf{e}_v = \mathbf{v}_{pd} - \mathbf{v}_p$ (14)

并令反馈增益为 $k_p, k_v > 0$ （标量），或者更一般地，令 $K_p, K_v \in \mathbb{R}^{3 \times 3}$ 为正定（对角）矩阵。期望载荷虚拟力为

$$\mathbf{F}_d = m_T (\mathbf{a}_{pd} + K_p \mathbf{e}_p + K_v \mathbf{e}_v + \mathbf{g}_{ez}) \quad (15)$$

随后，平行控制分量选择为

$$\mathbf{u}_{\parallel} = \mathbf{q}^{\top} \mathbf{F}_d + m_l \|\boldsymbol{\Omega}\|^2 \mathbf{q} - \mathbf{f}_{ap} \quad (16)$$

为了调节缆索方向，定义期望方向

$$\mathbf{q}_d = \frac{-\mathbf{F}_d}{\|\mathbf{F}_d\|}, \quad (17)$$

并令 $\boldsymbol{\Omega}_d$ 满足运动学关系 $\dot{\boldsymbol{\Omega}}_d = \dot{\mathbf{q}}_d \times \mathbf{q}_d$ ，其中 $\dot{\mathbf{q}}_d$ 是通过将 $\mathbf{q}_d$ 进行数值微分计算得到的，或者理想情况下是通过 Tang 等人提出的微分平坦性计算得到的。(2014) 中表示为

$$\dot{\mathbf{q}}_d = \frac{\mathbf{m} \mathbf{a}_{ind} + \mathbf{T} \mathbf{a}_d}{\|\mathbf{m} \mathbf{p}_d + \mathbf{g} \mathbf{e}_z\|}, \quad \mathbf{T} = \mathbf{m} \mathbf{p}(\mathbf{j}_d \cdot \mathbf{q}_d). \quad (18)$$

定义缆索姿态和角速率误差（与 Sreenath 等人 (2013)；Yu 等人 (2020) 的定义一致）为 $\mathbf{e}_q = \mathbf{q}_d \times \mathbf{q}$, $\mathbf{e}_\Omega = \boldsymbol{\Omega}_d - \boldsymbol{\Omega}$, (19)

并选择正增益 $k_q, k_\Omega > 0$ （或正定对角矩阵 $\mathbf{K}_q, \mathbf{K}_\Omega$ ）。利用 (11) 式中的缆索动力学，实现 $(\mathbf{q}, \boldsymbol{\Omega}) \rightarrow (\mathbf{q}_d, \boldsymbol{\Omega}_d)$ 稳定的垂直控制律为

$$\mathbf{u}^\perp = m_l \hat{\mathbf{q}}_1 (-\mathbf{K}_q \mathbf{e}_q - \mathbf{K}_\Omega \mathbf{e}_\Omega - (\mathbf{q} \cdot \boldsymbol{\Omega}_d) \dot{\mathbf{q}} - \hat{\mathbf{q}}^2 \dot{\boldsymbol{\Omega}}_d - \mathbf{f}_{ac}), \quad (20)$$

最后，定义四旋翼飞行器的总推力为 $f = \mathbf{u}_0 \cdot \mathbf{R} \mathbf{e}_z$ ，并利用 Lee 等人 (2010) 提出的几何控制器进行姿态跟踪。

B.1. INDI 形式化

在几何 INDI 框架中，残余气动力 $\mathbf{f}_{ap}$ 和 $\mathbf{f}_{ac}$ 分别对应于作用在负载和缆索上的未建模扰动，正如 (11) 式中的动力学方程所定义的那样。 $\mathbf{f}_{ap}$ 项捕捉了负载的实测加速度 $\ddot{\mathbf{x}}_p$ （等式左侧）与模型预测的标称加速度（等式右侧）之间的差异。类似地， $\mathbf{f}_{ac}$ 是根据缆索的实测角加速度 $\dot{\boldsymbol{\Omega}}$ 导出得到的。INDI 控制器利用这些残差，根据实测动力学与模型预测动力学之间的差值（如式 (16) 和 (20) 所示）来增量式地调整控制输入。

B.1.1. 实际实现

尽管上一节给出了理论推导，但该公式的实际实现面临着重大挑战。下文概述了传感与数值微分方面的要求，以及导致在轻型多旋翼硬件上进行实时实现变得困难的估计噪声来源。在我们的实验设置中，载荷位置 $\mathbf{p}_p$ 直接由运动捕捉（MoCap）系统测量。载荷加速度 $\mathbf{a}_p$ 是通过对测得的位置数据进行两次数值微分来估计的；在每次微分步骤之后，均采用巴特沃斯（Butterworth）滤波器进行处理，以获得平滑的速度和加速度估计值。同样地，缆索方向 $\mathbf{q}$ 是根据四旋翼飞行器和载荷的测量位置计算得出的。缆索角速度 $\boldsymbol{\Omega}$ 和角加速度 $\dot{\boldsymbol{\Omega}}$ 是通过对 $\mathbf{q}$ 进行数值微分并采用同样的巴特沃斯滤波方法（在每次

.....步骤)。在实际应用中，这需要在信号噪声和测量延迟之间进行权衡：较高的滤波器截止频率会产生噪声较大但响应更快的信号，而较低的截止频率则能产生更平滑的估计值，但代价是增加了延迟。注：原则上，可以像 Sun 等人 (2025) 那样，针对载荷和缆索状态实现扩展卡尔曼滤波器 (EKF)。然而，由于载荷动力学与四旋翼飞行器的动力学紧密耦合，导致估计过程涉及大规模矩阵求逆运算，这对 Crazyflie 平台的 STM32 固件来说计算负担过重。

B.1.2. 讨论

基于上述实际实现，我们现在探讨 INDI 方案的局限性及潜在的改进方向。原则上，本文并未对所提出的 INDI 方案进行实验验证，因为估计出的状态要么受到数值微分引入的显著噪声影响，要么受到使用低截止频率巴特沃斯 (Butterworth) 滤波器所引入延迟的影响。特别是缆索角加速度 $\dot{\Omega}$ 的估计对测量噪声高度敏感 (即使经过滤波处理)，导致残余力估计值的噪声过大，无法获得可靠的实验结果。尽管如此，我们仍纳入了这一方案，因为它代表了一种直接源自系统动力学的、理论上一致的方法。相比之下，正文中使用的 INDI 方案则是建模保真度与实际可行性之间的一种权衡。通过舍弃显式的缆索动力学模型，并依赖多旋翼飞行器 IMU 测得的加速度 (该加速度已通过缆索张力包含了耦合效应)，控制器在假设完全掌握这些效应的同时，获得了更平滑的残余量估计和更好的实时稳定性。应对这些挑战的一个有前景的方向是利用数据驱动模型直接学习残余动力学，其中输入的时间序列历史隐式地捕捉了高阶状态信息，从而降低了对显式状态估计的依赖。该分析为未来的工作奠定了基础，即结合学习到的残余模型与状态估计方法，实现基于 INDI 的缆索悬挂系统可靠控制。